Statistique descriptive et régression sous R

Partie 1 : données socio-économiques (CPS 2012) — Partie 2 : régression sur Boston (1970)

Menad Acheraiou et Belgacem Smaali

04/11/2026

Table des matières

1 Introduction **2**

2 Partie 1 : Recensement (CPS, 2012) **2**
2.1 Données et méthodes 2
2.2 Résultats 3
2.3 Discussion critique de la Partie 1 10

3 Partie 2 : Régression sur Boston (1970) **11**
3.1 Données et méthodes 11
3.2 Résultats 11
3.3 Discussion critique de la Partie 2 13

4 Conclusion **13**

5 Bibliographie **13**

Annexes **14**

1 Introduction

À rédiger (environ 0,5 page). Présenter l'objectif du travail, les deux jeux de données (enquête CPS de juillet 2012 ; recensement de 1970 pour Boston), le caractère **historique** et **descriptif** de l'étude, et le plan du rapport.

2 Partie 1 : Recensement (CPS, 2012)

2.1 Données et méthodes

2.1.1 Vue d'ensemble

Les données viennent de l'enquête américaine *Current Population Survey* (CPS) de juillet 2012. Ce sont des données historiques : elles décrivent le marché du travail de 2012 et non la situation actuelle. Le fichier `Recensement.txt` est importé avec `read.table()` (séparateur tabulation, ligne d'en-tête). Il contient 599 lignes et 11 variables, et chaque ligne est un individu : l'unité statistique est la personne enquêtée. Le sujet ne précise pas comment ces personnes ont été choisies. Nous ne présentons donc pas l'échantillon comme représentatif de la population américaine : tous les résultats portent sur ces 599 individus. Le fichier ne contient ni nom ni adresse, ce qui permet d'afficher les premières lignes sans risque d'identification (tableau 1). Tous les tableaux, chiffres et figures de cette partie sont régénérés par le script `tp_partie1.R` et par ce document R Markdown.

Tableau 1: Cinq premières lignes du fichier Recensement.txt (n = 599)

AGE	SEXE	REGION	STAT_MARI	SAL_HOR	SYNDICAT	CATEGORIE	NIV_ETUDES	NB_PERS	NB_ENF	REV_FOYER
58	F	NE	C	13,25	non	5	43	2	0	11
40	M	W	M	12,50	non	7	38	2	0	7
29	M	S	C	14,00	non	5	42	2	0	15
59	M	NE	D	10,60	oui	3	39	4	1	7
51	M	W	M	13,00	non	3	35	8	1	15

Fonctions R utilisées : `read.table()` (import), `dim()`, `head()`, `str()`, `class()` (structure), `is.na()`, `duplicated()`, `unique()` (contrôles), `table()`, `prop.table()` (effectifs et fréquences, globales ou conditionnelles), `cut()` (regroupement des codes), `subset()` (catégories 1, 2 et 5), `mean()`, `median()`, `sd()`, `var()`, `quantile()`, `IQR()` (position et dispersion), `aggregate()`, `tapply()` (indicateurs par groupe), `barplot()`, `hist()`, `boxplot()`, `plot()` (graphiques), `ecdf()` (fonction de répartition), `cor()` et `lowess()` (corrélation et courbe de tendance).

2.1.2 Dictionnaire des variables

Tableau 2: Dictionnaire et contrôle des variables (n = 599)

Variable	Signification	Type statistique	Type R	Manquants	Distinctes	Modalités ou étendue observées
AGE	âge (années)	quanti. discrète	integer	0	59	16 à 80
SEXE	sexe	quali. nominale	character	0	2	F 297, M 302
REGION	région	quali. nominale	character	0	4	NE 129, NW 122, S 200, W 148
STAT_MARI	statut marital	quali. nominale	character	0	5	C 193, D 61, M 325, S 14, V 6
SAL_HOR	salaire horaire ($/h)	quanti. continue	numeric	0	223	2 à 99
SYNDICAT	syndiqué	quali. nominale (binaire)	character	0	2	non 496, oui 103
CATEGORIE	catégorie prof.	quali. nominale (codes)	integer	0	10	1 à 10
NIV_ETUDES	niveau d'études	quali. ordinale (codes)	integer	0	15	32 à 46
NB_PERS	taille du foyer	quanti. discrète	integer	0	9	1 à 13
NB_ENF	enfants du foyer	quanti. discrète	integer	0	7	0 à 6
REV_FOYER	revenu annuel du foyer	quali. ordinale (classes)	integer	0	16	1 à 16

Le tableau 2 met en regard le type statistique et le type R ; les deux ne coïncident pas toujours. NIV_ETUDES est stocké en entier, mais ses codes de 32 à 46 ne mesurent pas une quantité : l'écart entre deux codes n'a pas

de sens. Ils suivent en revanche l'ordre des diplômes, ce qui en fait une variable qualitative ordinale. Nous ne calculons donc jamais de moyenne des codes. CATEGORIE est aussi un entier, mais ses 10 codes désignent des métiers sans ordre naturel : c'est une variable nominale codée, traitée comme un facteur. REV_FOYER est à l'origine un revenu, donc une grandeur continue, mais le fichier ne donne que la classe (de 1 à 16) : on la traite comme une variable ordinale en classes. SAL_HOR est continue (223 valeurs distinctes, avec des centimes) ; AGE, NB_PERS et NB_ENF sont des comptages entiers.

La région est codée NE, NW, S, W dans le fichier, alors que le sujet annonce MW : aucune ligne ne porte ce code (0 cas). Nous gardons le codage du fichier, NW tenant la place de la modalité MW du sujet. Les contrôles de base ne révèlent rien : 0 valeur manquante sur l'ensemble du fichier et 0 ligne en double (`duplicated()`).

2.1.3 Règles de contrôle et population analysée

Tableau 3: Règles de contrôle : nombre de cas signalés, aucune suppression (n = 599)

Règle	Justification	Cas signalés
AGE $<$ 16 ou $>$ 80 ans	hors de l'étendue annoncée	0
AGE $<$ 18 ans	mineur en emploi, possible mais à repérer	4
SAL_HOR $\leq$ 0	salaire impossible	0
SAL_HOR $<$ 7,25 \$/h	sous le salaire minimum fédéral de 2012	17
SAL_HOR $>$ 75 \$/h	très haut salaire, à vérifier	2
NB_ENF $\geq$ NB_PERS	un foyer compte au moins un adulte	0
NB_PERS $>$ 10	foyer exceptionnellement grand	1

Le tableau 3 applique sept règles. Une valeur suspecte n'est pas forcément fausse : aucune ligne n'est supprimée. Les 4 personnes de moins de 18 ans peuvent travailler légalement. Les 17 salaires inférieurs au minimum fédéral (de 2,00 à 7,15 \$/h) peuvent venir d'emplois à pourboires ou de cas exemptés. Les 2 salaires au-dessus de 75 \$/h valent 90 et 99 \$/h : un cadre peut gagner autant, mais une valeur ronde comme 99 pourrait aussi être un plafond de saisie, ce que le dictionnaire fourni ne permet pas de vérifier. Le foyer de 13 personnes est rare, pas impossible.

Le salaire est renseigné et strictement positif pour tous les individus (599 valides, 0 exclu). La population analysée pour SAL_HOR est donc l'échantillon complet, n = 599. Ce choix pèse peu sur le centre de la distribution : sans les 19 salaires signalés (bas et hauts), la moyenne passerait de 17,90 à 18,03 \$/h, et la médiane resterait à 15 \$/h.

2.2 Résultats

2.2.1 Décrire la population

Toutes les fréquences du tableau 4 ont le même dénominateur, les 599 individus, puisque aucune valeur ne manque. L'échantillon est équilibré entre femmes (297, soit 49,6 %) et hommes (302). Le Sud regroupe 33,4 % des personnes, les trois autres régions entre 20,4 et 24,7 %. Un peu plus de la moitié des enquêtés sont codés M (54,3 %), et 17,2 % sont syndiqués. Les catégories 2 et 3 sont les plus nombreuses (22,2 et 20,9 %). La catégorie 6 ne compte que 10 personnes : toute statistique calculée sur elle serait fragile.

Tableau 4: Effectifs et fréquences (%) ; dénominateur commun n = 599 individus

Variable	Modalité	n	%
Sexe	F	297	49,6
	M	302	50,4
Syndicat	non	496	82,8
	oui	103	17,2
Région	NE	129	21,5
	NW	122	20,4
	S	200	33,4
	W	148	24,7
Statut marital	C	193	32,2
	D	61	10,2
	M	325	54,3
	S	14	2,3
	V	6	1,0

Variable	Modalité	n	%
Catégorie	1	46	7,7
	2	133	22,2
	3	125	20,9
	4	48	8,0
	5	94	15,7
	6	10	1,7
	7	36	6,0
	8	32	5,3
	9	39	6,5
	10	36	6,0

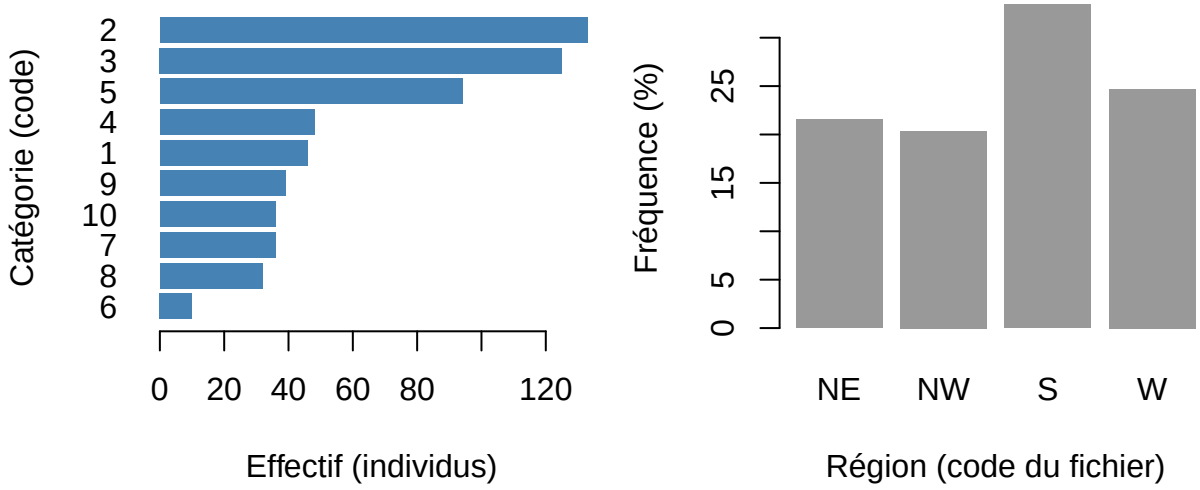


Figure 1: Effectifs par catégorie professionnelle, triés (à gauche) et répartition par région en % (à droite), n = 599

Pour des variables qualitatives, le diagramme en barres se lit mieux qu'un diagramme circulaire : l'œil compare des longueurs plus facilement que des angles. Pour les 10 catégories (figure 1, à gauche), le tri et les barres horizontales donnent le classement d'un coup d'œil et gardent les codes lisibles. Pour la région, l'axe en pourcentage permet de comparer des parts proches, comme NE (21,5 %) et NW (20,4 %), qu'un camembert rendrait presque identiques.

Tableau 5: Niveau d'études : codes d'origine de NIV_ETUDES (n = 599)

	32	33	34	35	36	37	38	39	40	41	42	43	44	45	46
Effectif	5	6	5	9	5	8	7	187	148	22	45	114	29	4	5

Tableau 6: Niveau d'études regroupé (n = 599)

Groupe	Codes	n	%
Secondaire ou moins	32-39	232	38,7
Postsec. sans bachelor	40-42	215	35,9
Bachelor	43	114	19,0
Master	44	29	4,8
École spécifique	45	4	0,7
Doctorat	46	5	0,8

Les codes bruts (tableau 5) sont très inégaux : 187 personnes ont le code 39 et 148 le code 40, alors que les codes 32 à 38 comptent chacun entre 5 et 9 individus. À ce niveau de détail, les pourcentages porteraient sur des effectifs trop faibles. Nous reprenons le découpage du sujet (tableau 6), qui respecte l'ordre des diplômes et rassemble les petits codes du secondaire. Les groupes « École spécifique » (4 personnes) et « Doctorat » (5) restent séparés, comme dans le sujet, mais leurs statistiques sont anecdotiques. Une variante défendable les réunirait avec le master en un groupe « au-delà du bachelor » de 38 personnes.

Tableau 7: Sexe puis niveau d'études selon la catégorie (% en ligne), n = 273

Catégorie	n	% F	% M	Sec.	Postsec.	Bach.	Master	École	Doct.
1 (gestion)	46	50,0	50,0	23,9	32,6	30,4	13,0	0,0	0,0
2 (libérale)	133	61,7	38,3	11,3	33,8	39,8	9,8	1,5	3,8
5 (bureau)	94	76,6	23,4	27,7	46,8	22,3	3,2	0,0	0,0

Le tableau 7 se lit en ligne : chaque catégorie fait 100 %, et les pourcentages sont conditionnels (part des femmes parmi les personnes de la catégorie, part de chaque niveau d'études parmi les personnes de la catégorie ; Sec., Postsec., Bach., École et Doct. désignent les six groupes du tableau 6). Les catégories diffèrent sur deux points. Pour le sexe, la catégorie 5 (bureau) compte 76,6 % de femmes, contre 50,0 % dans la catégorie 1, alors que les femmes forment 49,6 % de l'échantillon. Pour les études, 54,9 % des membres de la catégorie 2 ont au moins un bachelor, contre 25,5 % dans la catégorie 5, où le groupe postsecondaire sans bachelor domine (46,8 %). Les niveaux rares reposent sur de très petits effectifs : la catégorie 2 compte 2 personnes d'école spécifique et 5 de doctorat.

Les effectifs bruts mèneraient ici à une erreur. La catégorie 2 compte plus de femmes (82) que la catégorie 5 (72) ; on pourrait en conclure qu'elle est plus féminisée. C'est l'inverse en proportion, parce que la catégorie 2 est plus grande (133 contre 94 personnes). Le choix du dénominateur compte aussi : sans l'argument `margin`, `prop.table()` divise par le total des 273 individus des trois catégories, et les femmes de la catégorie 5 en représentent alors 26,4 %. Ce pourcentage global décrit la composition du sous-ensemble ; il ne permet pas de comparer les catégories entre elles.

2.2.2 Distributions et indicateurs

Tableau 8: Indicateurs de position et de dispersion (effectif valide n)

Variable	n	Moyenne	Médiane	Écart-type	Q1	Q3	Min	Max
AGE (années)	599	41,85	42	14,12	29,0	53,5	16	80
SAL_HOR ($/h)	599	17,90	15	11,28	10,5	22,0	2	99
NB_PERS (personnes)	599	3,11	3	1,56	2,0	4,0	1	13
NB_ENF (enfants)	599	0,53	0	0,92	0,0	1,0	0	6

Pour les quatre variables, l'effectif valide est de 599 (tableau 8). Nous donnons à la fois moyenne et médiane, écart-type et quartiles : la comparaison des deux centres renseigne sur la symétrie, et les quartiles résistent aux valeurs extrêmes. L'âge est à peu près symétrique (moyenne 41,85 ans, médiane 42 ans). Pour NB_ENF, la médiane de 0 dit seulement qu'une majorité de foyers n'a pas d'enfant (68,9 %) ; la moyenne (0,53) complète cette information pour une variable discrète à peu de valeurs.

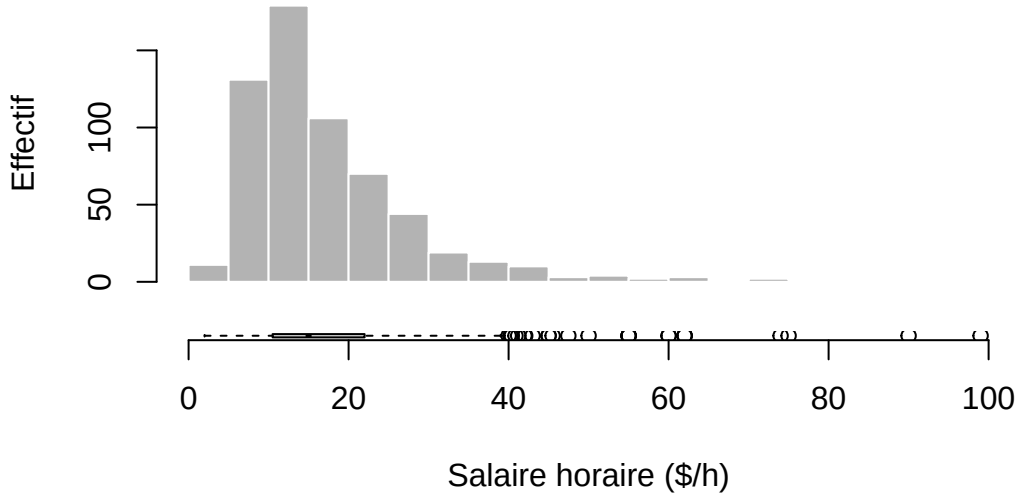


Figure 2: Distribution du salaire horaire ($/h) : histogramme en classes de 5 $/h et boîte à moustaches, n = 599

La distribution est nettement asymétrique à droite (figure 2). La classe la plus fréquente est 10–15 $/h (179 personnes), la moitié centrale des salaires tient entre 10,5 et 22 $/h, puis une longue queue s'étire jusqu'à 99 $/h. La boîte résume le centre et la dispersion, mais elle ne montre ni le mode ni la concentration des salaires sur des montants ronds. 57,4 % des salaires sont des nombres entiers de dollars, et 10 $/h apparaît à lui seul 33 fois, ce que seul un histogramme fin fait apparaître.

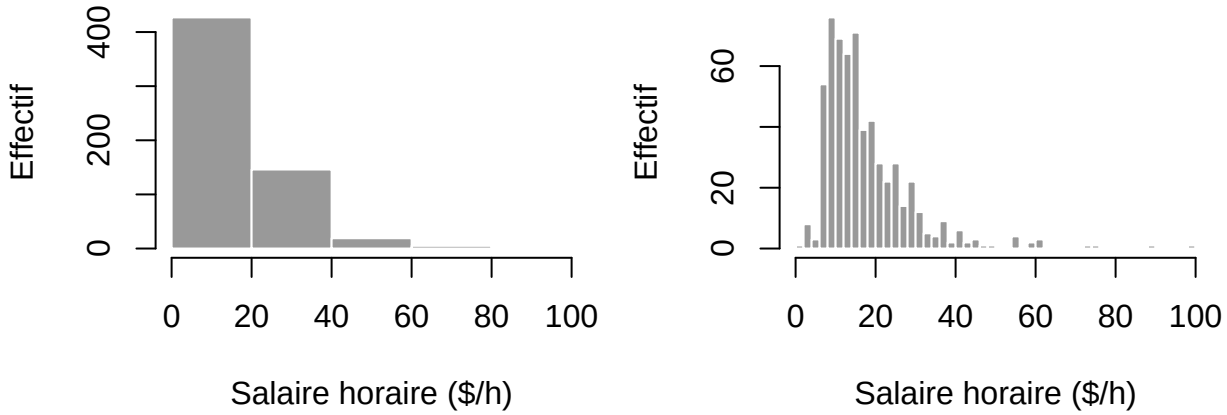


Figure 3: Deux découpages du salaire horaire ($/h) : classes de 20 $/h (à gauche) et de 2 $/h (à droite), n = 599

Le découpage change la lecture (figure 3). Avec 5 classes de 20 $/h, 71,3 % des individus tombent dans la première classe : on ne voit plus où se situe le mode, et la queue paraît se réduire à quelques barres. Avec 50 classes de 2 $/h, des pics isolés apparaissent sur les montants ronds et le dessin devient irrégulier ; certaines

classes ne contiennent qu'un ou deux individus. Un découpage intermédiaire, comme celui de la figure 2, montre mieux la forme générale.

La moyenne du salaire horaire (17,90 $/h) dépasse la médiane (15 $/h) de 2,90 $/h, signe de l'asymétrie à droite : quelques salaires élevés tirent la moyenne vers le haut. La médiane décrit mieux le salaire « typique » de l'échantillon, la moyenne reste utile pour raisonner sur des totaux (une masse salariale, par exemple). Pour mesurer la sensibilité aux valeurs extrêmes, nous avons retiré les deux plus hauts salaires : la moyenne descend à 17,64 $/h, la médiane ne bouge pas (15 $/h).

L'écart interquartile vaut 11,5 $/h. La règle de 1,5 × IQR place les moustaches à -6,75 et 39,25 $/h. La borne basse est négative, donc aucun salaire ne peut se trouver en dessous ; 27 salaires dépassent la borne haute, de 40 à 99 $/h. Ces observations ne sont pas pour autant des erreurs : dans une distribution asymétrique, la règle signale des valeurs éloignées du centre, pas des valeurs fausses. Un salaire de 50 $/h (leur médiane) n'a rien d'invraisemblable pour un poste d'encadrement. Seuls les deux salaires supérieurs à 75 $/h méritent la vérification décrite plus haut.

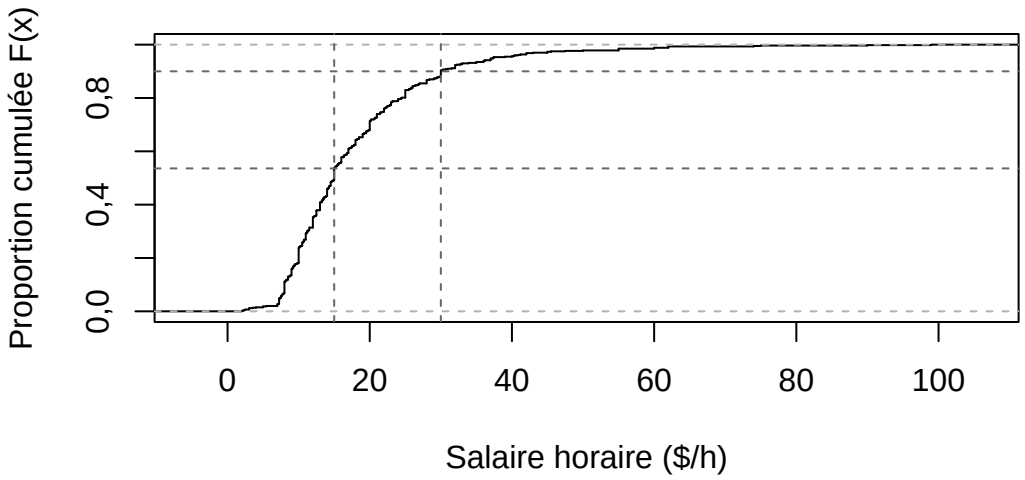


Figure 4: Fonction de répartition empirique du salaire horaire ($/h), n = 599

La fonction de répartition (figure 4) monte vite jusqu'à 30 $/h puis plafonne près de 1, ce qui traduit la même queue à droite. On y lit que F(15) = 0,536 : 53,6 % des individus gagnent au plus 15 $/h. Dans l'autre sens, le quantile d'ordre 0,9 vaut 30 $/h : 90 % des salaires sont inférieurs ou égaux à ce montant. Les marches verticales sur les montants ronds rappellent l'accumulation déjà vue.

La variance descriptive divise la somme des carrés des écarts à la moyenne par n ; elle décrit la dispersion des valeurs observées. La variance corrigée divise par $n - 1$; elle sert à estimer la variance d'une population dont l'échantillon serait tiré, sans biais. La fonction `var()` de R utilise $n - 1$, dès qu'il y a au moins deux observations valides. Ici, `var(d$SAL_HOR)` donne 127,22 et la version descriptive 127,01 ($/h)². Le rapport entre les deux vaut $(n - 1)/n$, soit un écart de 0,17 % avec n = 599 : la distinction compte surtout pour de petits groupes.

2.2.3 Comparer et interpréter

Tableau 9: Salaire horaire ($/h) dans les catégories 1, 2 et 5 (n = 273)

Catégorie	n	Moyenne	Médiane	Écart-type	Q1	Q3
1 (gestion)	46	25,22	20	16,41	14,25	30
2 (libérale)	133	23,93	20	13,73	15,00	30
5 (bureau)	94	15,16	14	4,40	12,00	18

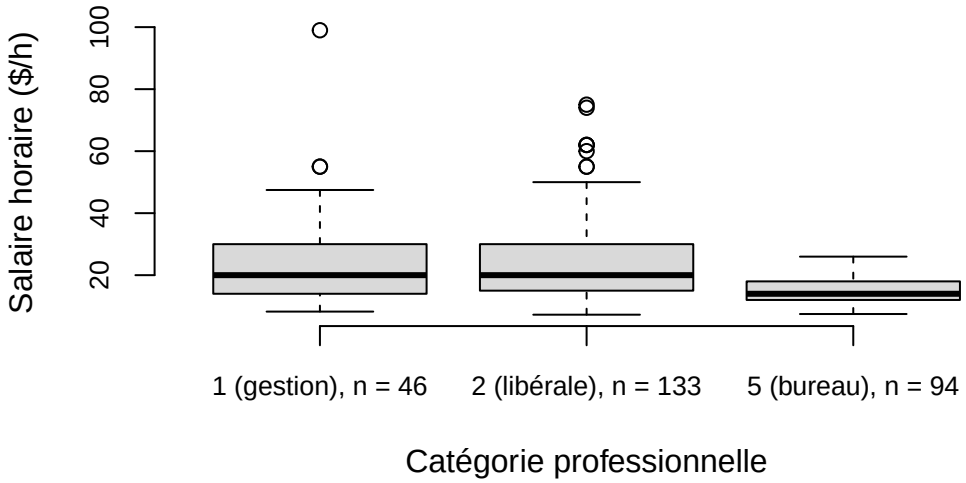


Figure 5: Salaire horaire ($/h) selon la catégorie professionnelle (1, 2 et 5), n = 273

Les catégories 1 et 2 ont la même médiane, 20 $/h, contre 14 $/h dans la catégorie 5 (tableau 9 et figure 5). La dispersion diffère plus encore que le centre : l'écart-type va de 4,4 $/h dans la catégorie 5 à 16,4 $/h dans la catégorie 1, et l'intervalle interquartile passe de 6,00 à 15,75 $/h. Les salaires de bureau sont donc à la fois plus bas et plus homogènes. La catégorie 1 repose sur 46 personnes seulement, et sa moyenne (25,22 $/h) dépend beaucoup de quelques hauts salaires.

Tableau 10: Salaire horaire ($/h) selon le sexe, ensemble puis catégories 1, 2 et 5

Champ	n F	Moyenne F	Médiane F	n M	Moyenne M	Médiane M
Ensemble (n = 599)	297	16,60	14,00	302	19,17	15,70
Catégorie 1 (gestion)	23	23,69	18,00	23	26,75	20,00
Catégorie 2 (libérale)	82	21,59	19,40	51	27,70	22,00
Catégorie 5 (bureau)	72	15,28	14,12	22	14,76	13,25

Sur l'ensemble de l'échantillon, la médiane des hommes dépasse celle des femmes de 1,7 $/h et la moyenne de 2,57 $/h (tableau 10). À l'intérieur des catégories, la conclusion n'est pas la même partout. L'écart en faveur des hommes s'observe dans les catégories 1 et 2, où il atteint 6,11 $/h en moyenne pour la catégorie 2. Dans la catégorie 5, il s'inverse : la médiane des femmes (14,12 $/h) dépasse celle des hommes (13,25 $/h). L'écart global peut aussi refléter la composition des catégories : les femmes sont surreprésentées dans la catégorie 5, la moins payée des trois. Les effectifs par cellule sont faibles (22 hommes dans la catégorie 5), ce qui interdit de généraliser.

Tableau 11: Salaire horaire ($/h) selon le niveau d'études regroupé (n = 599)

Groupe	n	Moyenne	Médiane
Secondaire ou moins	232	14,70	12,50
Postsec. sans bachelor	215	16,58	14,50
Bachelor	114	23,27	18,25
Master	29	26,89	19,80
École spécifique	4	18,53	18,56
Doctorat	5	48,20	37,00

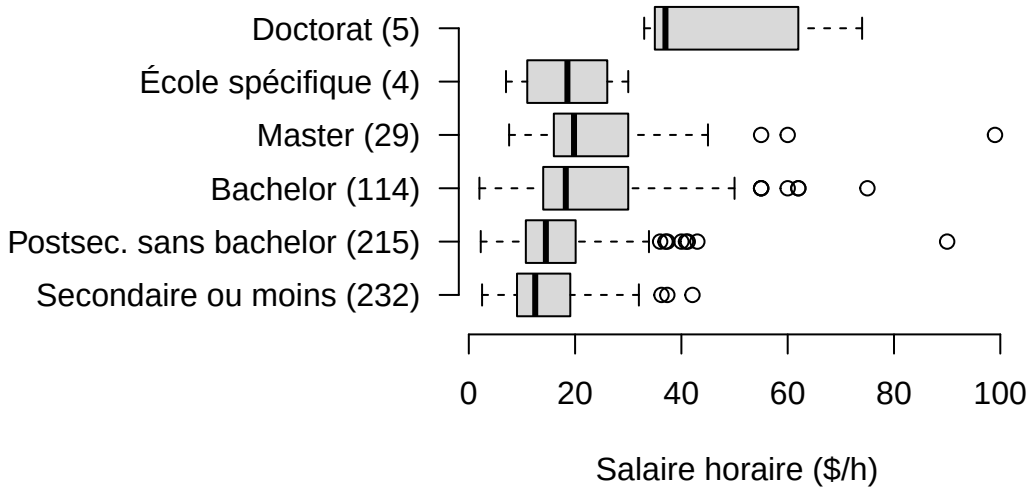


Figure 6: Salaire horaire ($/h) selon le niveau d'études regroupé, n = 599

La médiane du salaire augmente avec le niveau d'études, de 12,5 $/h pour le secondaire ou moins à 18,25 $/h pour le bachelor et 19,8 $/h pour le master (tableau 11, figure 6). Le doctorat affiche 37 $/h, mais sur 5 personnes. Le rapport de corrélation vaut $\eta^2 = 0{,}171$: c'est la part de la variance totale du salaire qui est inter-groupes (il varie de 0, groupes de même moyenne, à 1, salaire constant dans chaque groupe), soit 17,1 % dans l'échantillon. C'est un indicateur purement descriptif. L'association est nette, mais elle ne prouve pas que le diplôme produit ces écarts : les plus diplômés peuvent aussi différer par leur métier, leur âge ou leur région, et rien ne permet ici de séparer ces facteurs.

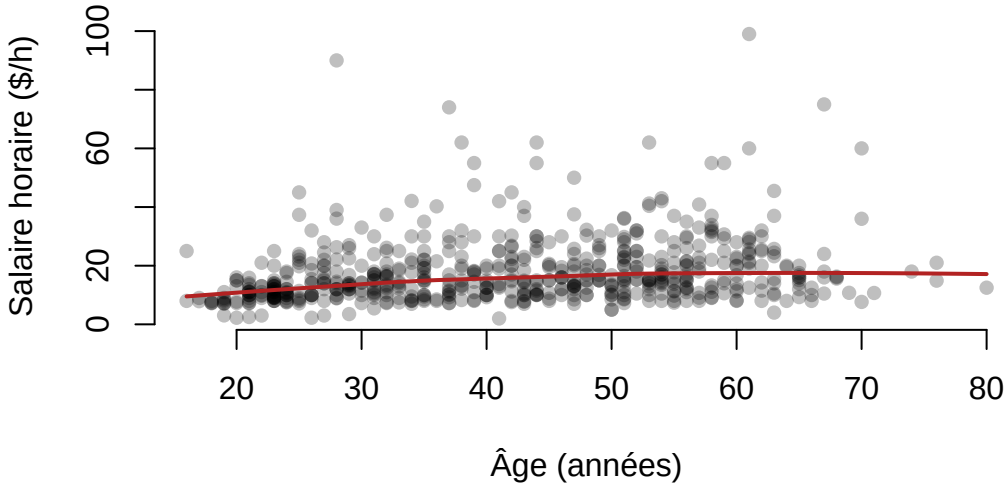


Figure 7: Salaire horaire ($/h) selon l'âge (années), avec courbe de tendance lowess, n = 599

Le nuage (figure 7) est très dispersé. La courbe lowess, qui suit les moyennes locales du nuage, monte d'environ 11 $/h à 20 ans à 16 $/h vers 45 ans, puis progresse peu (17 $/h à 60 ans). Le coefficient de corrélation linéaire est faible, r = 0,250, en partie parce que la relation n'est pas une droite. Les données sont de plus transversales : elles comparent des personnes de générations différentes en 2012, pas l'évolution du salaire d'une même personne. La courbe repose enfin sur peu d'observations aux âges extrêmes.

Tableau 12: Part de syndiqués selon la catégorie (% en ligne), n = 599

	1	2	3	4	5	6	7	8	9	10
n	46	133	125	48	94	10	36	32	39	36
% syndiqués	10,9	24,8	16,0	6,2	10,6	0,0	33,3	25,0	17,9	13,9

La part de syndiqués varie de 0,0 % (catégorie 6, n = 10) à 33,3 % (catégorie 7, n = 36) pour une moyenne de 17,2 % (tableau 12) ; ces extrêmes reposent sur de petits effectifs et se lisent avec prudence. Ici encore, les effectifs bruts tromperaient : la catégorie 2 compte le plus de syndiqués (33), mais pas le taux le plus élevé. Sur l'ensemble, la médiane des syndiqués (20 $/h, n = 103) dépasse celle des non-syndiqués (14 $/h, n = 496). Dans la catégorie 2, la seule où les syndiqués sont assez nombreux (n = 33, contre 100 non-syndiqués), l'ordre s'inverse : 17 $/h contre 20 $/h. Avec 5 syndiqués dans la catégorie 1 et 10 dans la catégorie 5, les données ne permettent pas de comparaison sérieuse.

En résumé, le salaire horaire est très asymétrique : la moyenne (17,90 $/h) dépasse la médiane (15 $/h) et 27 valeurs dépassent la moustache haute. Il est associé au niveau d'études, avec une médiane qui passe de 12,5 à 18,25 $/h entre le secondaire et le bachelor. L'écart entre hommes et femmes observé sur l'ensemble (1,7 $/h de médiane) ne se retrouve pas dans toutes les catégories et s'inverse dans la catégorie 5. Ces résultats ont deux limites. L'échantillon de 599 personnes n'est pas décrit comme représentatif, et certains sous-groupes sont minuscules (4 personnes pour l'école spécifique, 22 hommes dans la catégorie 5). Des variables importantes manquent, comme la durée du travail ou l'ancienneté, et les données datent de 2012.

2.3 Discussion critique de la Partie 1

Une différence de salaire entre deux groupes ne prouve ni une discrimination ni un lien de cause à effet. Les groupes comparés diffèrent sur d'autres points que celui qui les définit, et ces différences de composition suffisent à créer ou à masquer un écart : la comparaison par sexe en donne un exemple, puisque l'écart global change de sens dans la catégorie 5. Établir une discrimination demanderait de comparer des personnes semblables sur tout le reste, ce qu'une enquête descriptive de ce type ne permet pas. Des variables absentes du fichier pourraient modifier les comparaisons : le temps de travail (temps partiel ou temps plein, heures supplémentaires), l'ancienneté dans l'emploi et le secteur (public ou privé).

Tableau 13: Répartition des classes de REV_FOYER (n = 599)

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
n	9	5	5	9	7	19	26	38	30	35	61	70	71	89	77	48
%	1,5	0,8	0,8	1,5	1,2	3,2	4,3	6,3	5,0	5,8	10,2	11,7	11,9	14,9	12,9	8,0

Les classes de revenu du foyer décrivent une répartition ordonnée (tableau 13) : la classe médiane est la classe 12, et les classes 1 à 5 réunissent 5,8 % des foyers. Elles permettent aussi de comparer des groupes par leurs fréquences de classes. En revanche, elles empêchent de calculer exactement une moyenne, une variance ou un écart entre deux foyers : on ne connaît que l'intervalle, les classes n'ont pas toutes la même largeur et un code de classe n'est pas un montant. Il s'agit en outre d'un revenu de foyer, qu'on ne peut pas rapprocher directement du salaire horaire individuel.

Le dictionnaire du sujet présente une discontinuité entre les classes 5 et 6 : la classe 5 va de 12 500 à 14 500 $ et la classe 6 commence à 15 000 $ pour finir à 20 000 $. Un revenu compris entre 14 500 et 15 000 $ n'aurait donc pas de classe. Nous avons vérifié les données : les 16 classes sont toutes présentes, la classe 5 avec 7 foyers et la classe 6 avec 19. Aucune classe ne manque : l'incohérence vient des bornes du dictionnaire, peut-être d'une erreur de saisie que seul le dictionnaire complet de la CPS permettrait de trancher. Nous n'avons rien corrigé, puisque l'analyse n'utilise que les codes.

Nous n'avons pas traité l'option de comparaison avec un indicateur récent du BLS ou du Census Bureau : elle supposerait de vérifier le champ, les définitions et la période, et nous avons préféré consacrer la place à l'analyse des données de 2012.

3 Partie 2 : Régression sur Boston (1970)

3.1 Données et méthodes

`MASS::Boston` : 506 secteurs. X = `lstat`, Y = `medv` (milliers de dollars).

À rédiger : méthodes (moindres carrés, `cor.test`, régressogramme, polynômes, AIC).

3.2 Résultats

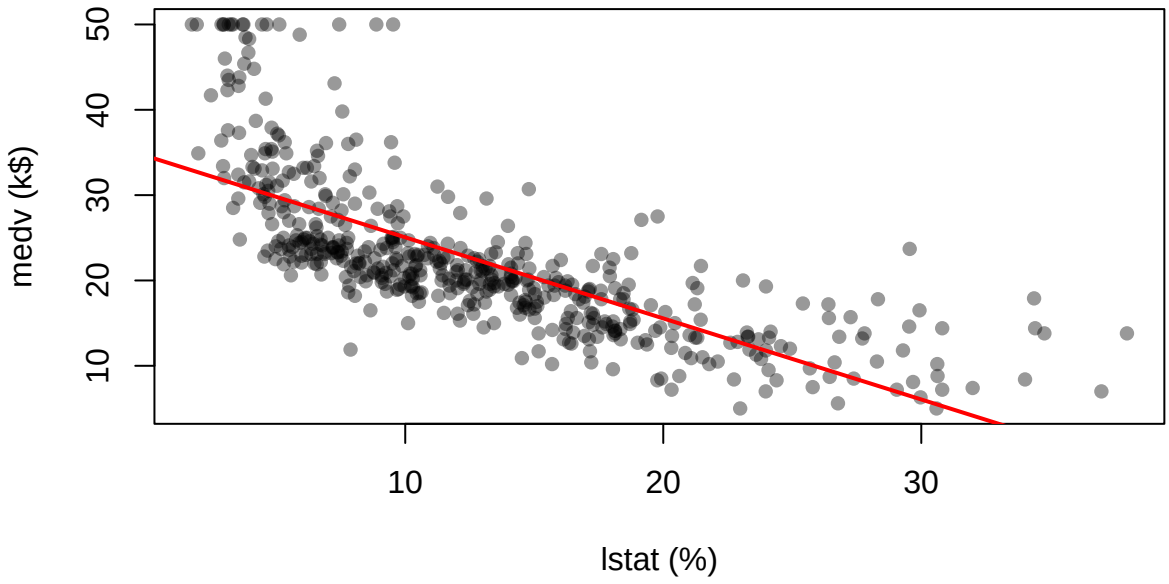


Figure 8: Valeur médiane des logements (k$) selon lstat (%), n = 506

Tableau 14: Droite des moindres carrés (medv en k$, lstat en %)

	Coefficient	Estimation
(Intercept)	Ordonnée à l'origine	34,554
lstat	Pente (lstat)	-0,950



Figure 9: Résidus du modèle linéaire (k$) : histogramme, boîte à moustaches et résidus selon lstat (lignes à ± 2 écarts-types empiriques)

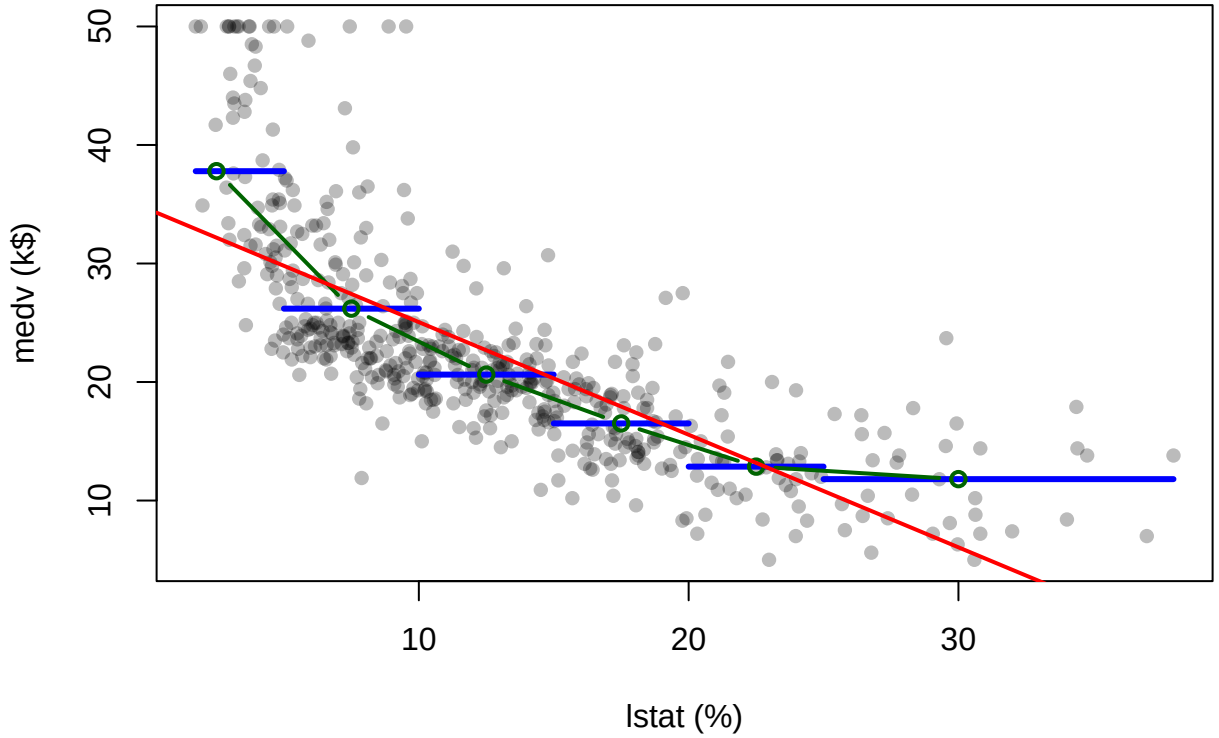


Figure 10: Régressogramme (moyennes de medv en k$ par classe de lstat), courbe des moyennes et droite de régression

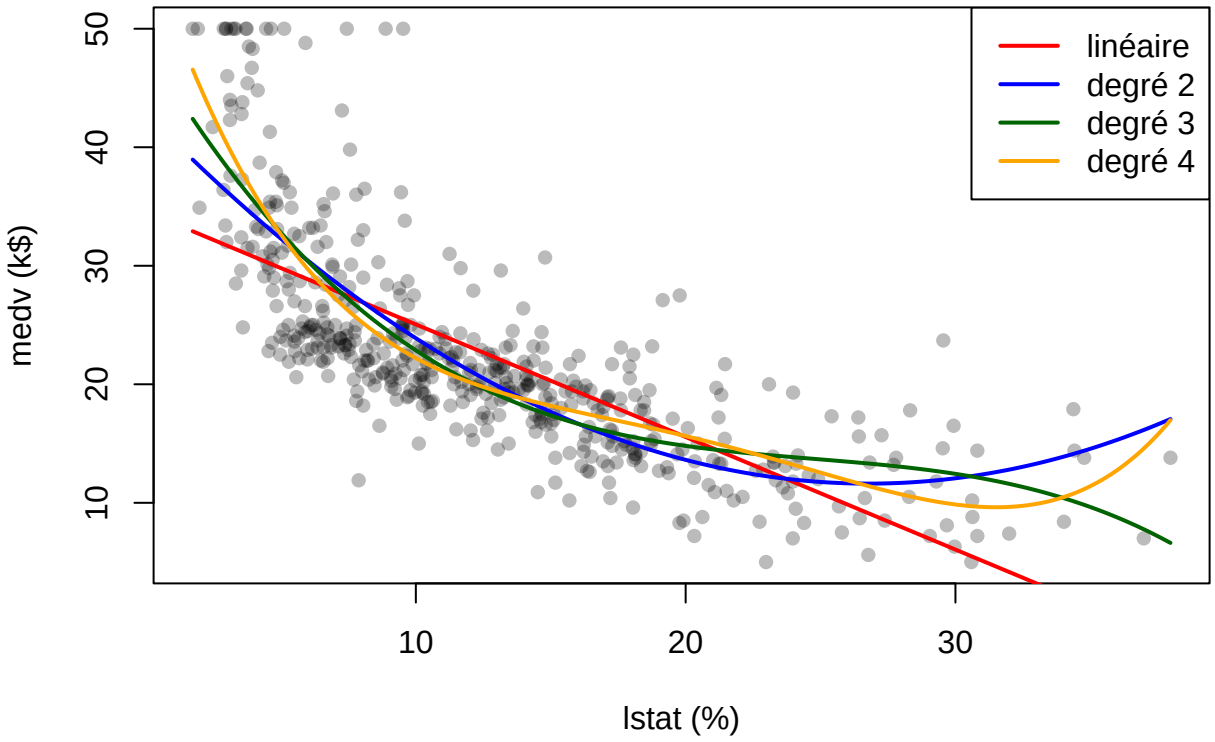


Figure 11: Ajustements linéaire et polynomiaux (degrés 2 à 4) de medv (k$) sur lstat (%)

Tableau 15: Comparaison des modèles : R^2 et AIC

Modèle	R^2	AIC
lin	0,544	3289,0
d2	0,641	3170,5
d3	0,658	3147,8
d4	0,673	3126,9

À rédiger : nuage, droite (formules et `lm()`), corrélation et R^2, test de Pearson, valeurs ajustées, résidus (`sd(residuals)` et `sigma`), prévision, régressogramme, polynômes de degré 2 à 4 et AIC.

3.3 Discussion critique de la Partie 2

À rédiger : limites des données de 1970 (plafond de medv à 50), absence de causalité, choix du modèle (AIC et complexité).

4 Conclusion

À rédiger : bilan des deux parties et limites communes (données anciennes, analyses descriptives).

5 Bibliographie

À compléter : sujet du TP, documentation de R et de `MASS`, sources éventuelles (BLS, Census Bureau).

Annexes

Sorties complémentaires et, si utile, le script (hors des 20 pages).