Statistique descriptive et régression sous R

Partie 1 : données socio-économiques (CPS 2012) — Partie 2 : régression sur Boston (1970)

Menad Acheraiou et Belgacem Smaali

09/11/2026

Table des matières

1 Introduction **2**

2 Partie 1 : Recensement (CPS, 2012) **2**
2.1 Données et méthodes 2
2.2 Résultats 4
2.3 Discussion critique de la Partie 1 11

3 Partie 2 : Régression sur Boston (1970) **11**
3.1 Données et méthodes 11
3.2 Résultats 12
3.3 Discussion critique de la Partie 2 17

4 Conclusion **17**

5 Bibliographie **17**

1 Introduction

Ce rapport présente deux analyses statistiques réalisées sous R. La première (Partie 1) explore le fichier `Recensement.txt`, issu de l'enquête américaine *Current Population Survey* de juillet 2012 : nous décrivons la population observée et nous étudions les salaires horaires selon la profession, le sexe et le niveau d'études. La seconde (Partie 2) étudie, sur le jeu `Boston` du package `MASS` (recensement américain de 1970), la relation entre la part de population de faible statut socio-économique (`lstat`) et la valeur médiane des logements (`medv`), par régression linéaire puis polynomiale.

Les deux jeux de données sont **historiques** et les analyses **descriptives** : elles décrivent ce qui est observé dans ces échantillons, sans prétendre à la situation actuelle, à une relation de cause à effet ou à une preuve de discrimination. Le rapport suit le plan suivant : pour chaque partie, données et méthodes, résultats commentés puis discussion critique ; une conclusion générale et la bibliographie terminent le document. Les scripts `tp_partie1.R` et `tp_partie2.R` et le fichier `rapport.Rmd` reproduisent l'ensemble des tableaux et des figures.

2 Partie 1 : Recensement (CPS, 2012)

2.1 Données et méthodes

2.1.1 Vue d'ensemble

Les données viennent de l'enquête américaine *Current Population Survey* (CPS) de juillet 2012. Ce sont des données historiques : elles décrivent le marché du travail de 2012 et non la situation actuelle. Le fichier `Recensement.txt` est importé avec `read.table()` (séparateur tabulation, ligne d'en-tête). Il contient 599 lignes et 11 variables, et chaque ligne est un individu : l'unité statistique est la personne enquêtée. Le sujet ne précise pas comment ces personnes ont été choisies. Nous ne présentons donc pas l'échantillon comme représentatif de la population américaine : tous les résultats portent sur ces 599 individus. Le fichier ne contient ni nom ni adresse, ce qui permet d'afficher les premières lignes sans risque d'identification (tableau 1). Tous les tableaux, chiffres et figures de cette partie sont régénérés par le script `tp_partie1.R` et par ce document R Markdown.

Tableau 1: Cinq premières lignes du fichier Recensement.txt (n = 599)

AGE	SEXE	REGION	STAT_MARI	SAL_HOR	SYNDICAT	CATEGORIE	NIV_ETUDES	NB_PERS	NB_ENF	REV_FOYER
58	F	NE	C	13,25	non	5	43	2	0	11
40	M	W	M	12,50	non	7	38	2	0	7
29	M	S	C	14,00	non	5	42	2	0	15
59	M	NE	D	10,60	oui	3	39	4	1	7
51	M	W	M	13,00	non	3	35	8	1	15

Fonctions R utilisées : `read.table()` (import), `dim()`, `head()`, `str()`, `class()` (structure), `is.na()`, `duplicated()`, `unique()` (contrôles), `table()`, `prop.table()` (effectifs et fréquences, globales ou conditionnelles), `cut()` (regroupement des codes), `subset()` (catégories 1, 2 et 5), `mean()`, `median()`, `sd()`, `var()`, `quantile()`, `IQR()` (position et dispersion), `aggregate()`, `tapply()` (indicateurs par groupe), `barplot()`, `hist()`, `boxplot()`, `plot()` (graphiques), `ecdf()` (fonction de répartition), `cor()` (corrélation), `segments()`, `lines()`, `legend()` (régressogramme de l'âge).

2.1.2 Dictionnaire des variables

Tableau 2: Dictionnaire et contrôle des variables (n = 599)

Variable	Signification	Type statistique	Type R	Manquants	Distinctes	Modalités ou étendue observées
AGE	âge (années)	quanti. discrète	integer	0	59	16 à 80
SEXE	sexe	quali. nominale	character	0	2	F 297, M 302
REGION	région	quali. nominale	character	0	4	NE 129, NW 122, S 200, W 148
STAT_MARI	statut marital	quali. nominale	character	0	5	C 193, D 61, M 325, S 14, V 6
SAL_HOR	salaire horaire ($/h)	quanti. continue	numeric	0	223	2 à 99
SYNDICAT	syndiqué	quali. nominale (binaire)	character	0	2	non 496, oui 103
CATEGORIE	catégorie prof.	quali. nominale (codes)	integer	0	10	1 à 10
NIV_ETUDES	niveau d'études	quali. ordinale (codes)	integer	0	15	32 à 46
NB_PERS	taille du foyer	quanti. discrète	integer	0	9	1 à 13
NB_ENF	enfants du foyer	quanti. discrète	integer	0	7	0 à 6
REV_FOYER	revenu annuel du foyer	quali. ordinale (classes)	integer	0	16	1 à 16

Le tableau 2 met en regard le type statistique et le type R ; les deux ne coïncident pas toujours. NIV_ETUDES est stocké en entier, mais ses codes de 32 à 46 ne mesurent pas une quantité : l'écart entre deux codes n'a pas de sens. Ils suivent en revanche l'ordre des diplômes, ce qui en fait une variable qualitative ordinale. Nous ne calculons donc jamais de moyenne des codes. CATEGORIE est aussi un entier, mais ses 10 codes désignent des métiers sans ordre naturel : c'est une variable nominale codée, traitée comme un facteur. REV_FOYER est à l'origine un revenu, donc une grandeur continue, mais le fichier ne donne que la classe (de 1 à 16) : on la traite comme une variable ordinale en classes. SAL_HOR est continue (223 valeurs distinctes, avec des centimes) ; AGE, NB_PERS et NB_ENF sont des comptages entiers.

La région est codée NE, NW, S, W dans le fichier, alors que le sujet annonce MW : aucune ligne ne porte ce code (0 cas). Nous gardons le codage du fichier, NW tenant la place de la modalité MW du sujet. Les contrôles de base ne révèlent rien : 0 valeur manquante sur l'ensemble du fichier et 0 ligne en double (`duplicated()`).

2.1.3 Règles de contrôle et population analysée

Tableau 3: Règles de contrôle : nombre de cas signalés, aucune suppression (n = 599)

Règle	Justification	Cas signalés
AGE $<$ 16 ou $>$ 80 ans	hors de l'étendue annoncée	0
AGE $<$ 18 ans	mineur en emploi, possible mais à repérer	4
SAL_HOR $\leq$ 0	salaire impossible	0
SAL_HOR $<$ 7,25 $/h	sous le salaire minimum fédéral de 2012	17
SAL_HOR $>$ 75 $/h	très haut salaire, à vérifier	2
NB_ENF $\geq$ NB_PERS	un foyer compte au moins un adulte	0
NB_PERS $>$ 10	foyer exceptionnellement grand	1

Le tableau 3 applique sept règles. Une valeur suspecte n'est pas forcément fausse : aucune ligne n'est supprimée. Les 4 personnes de moins de 18 ans peuvent travailler légalement. Les 17 salaires inférieurs au minimum fédéral (de 2,00 à 7,15 $/h) peuvent venir d'emplois à pourboires ou de cas exemptés. Les 2 salaires au-dessus de 75 $/h valent 90 et 99 $/h : un cadre peut gagner autant, mais une valeur ronde comme 99 pourrait aussi être un plafond de saisie, ce que le dictionnaire fourni ne permet pas de vérifier. Le foyer de 13 personnes est rare, pas impossible.

Le salaire est renseigné et strictement positif pour tous les individus (599 valides, 0 exclu). La population analysée pour SAL_HOR est donc l'échantillon complet, n = 599. Ce choix pèse peu sur le centre de la distribution : sans les 19 salaires signalés (bas et hauts), la moyenne passerait de 17,90 à 18,03 $/h, et la médiane resterait à 15 $/h.

Tableau 4: Effectifs et fréquences (%) ; dénominateur commun n = 599 individus

Variable	Modalité	n	%	Variable	Modalité	n	%
Sexe	F	297	49,6	Catégorie	1	46	7,7
	M	302	50,4		2	133	22,2
Syndicat	non	496	82,8		3	125	20,9
	oui	103	17,2		4	48	8,0
Région	NE	129	21,5		5	94	15,7
	NW	122	20,4		6	10	1,7
	S	200	33,4		7	36	6,0
	W	148	24,7		8	32	5,3
Statut marital	C	193	32,2		9	39	6,5
	D	61	10,2		10	36	6,0
	M	325	54,3				
	S	14	2,3				
	V	6	1,0				

2.2 Résultats

2.2.1 Décrire la population

Toutes les fréquences du tableau 4 ont le même dénominateur, les 599 individus, puisque aucune valeur ne manque. L'échantillon est équilibré entre femmes (297, soit 49,6 %) et hommes (302). Le Sud regroupe 33,4 % des personnes, les trois autres régions entre 20,4 et 24,7 %. Un peu plus de la moitié des enquêtés sont codés M (54,3 %), et 17,2 % sont syndiqués. Les catégories 2 et 3 sont les plus nombreuses (22,2 et 20,9 %). La catégorie 6 ne compte que 10 personnes : toute statistique calculée sur elle serait fragile.

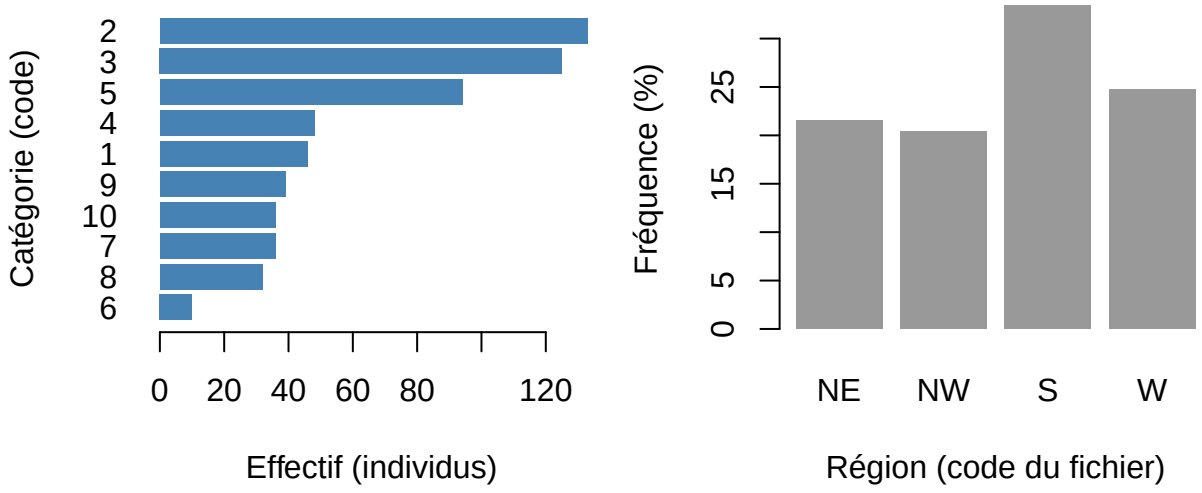


Figure 1: Effectifs par catégorie professionnelle, triés (à gauche) et répartition par région en % (à droite), n = 599

Pour des variables qualitatives, le diagramme en barres se lit mieux qu'un diagramme circulaire : l'œil compare des longueurs plus facilement que des angles. Pour les 10 catégories (figure 1, à gauche), le tri et les barres horizontales donnent le classement d'un coup d'œil et gardent les codes lisibles. Pour la région, l'axe en pourcentage permet de comparer des parts proches, comme NE (21,5 %) et NW (20,4 %), qu'un camembert rendrait presque identiques.

Tableau 5: Niveau d'études : codes d'origine de NIV_ETUDES (n = 599)

	32	33	34	35	36	37	38	39	40	41	42	43	44	45	46
Effectif	5	6	5	9	5	8	7	187	148	22	45	114	29	4	5

Tableau 6: Niveau d'études regroupé (n = 599)

Groupe	Codes	n	%
Secondaire ou moins	32-39	232	38,7
Postsec. sans bachelor	40-42	215	35,9
Bachelor	43	114	19,0
Master	44	29	4,8
École spécifique	45	4	0,7
Doctorat	46	5	0,8

Les codes bruts (tableau 5) sont très inégaux : 187 personnes ont le code 39 et 148 le code 40, alors que les codes 32 à 38 comptent chacun entre 5 et 9 individus. À ce niveau de détail, les pourcentages porteraient sur des effectifs trop faibles. Nous reprenons le découpage du sujet (tableau 6), qui respecte l'ordre des diplômes et rassemble les petits codes du secondaire. Les groupes « École spécifique » (4 personnes) et « Doctorat » (5) restent séparés, comme dans le sujet, mais leurs statistiques sont anecdotiques. Une variante défendable les réunirait avec le master en un groupe « au-delà du bachelor » de 38 personnes.

Tableau 7: Sexe puis niveau d'études selon la catégorie (% en ligne), n = 273

Catégorie	n	% F	% M	Sec.	Postsec.	Bach.	Master	École	Doct.
1 (gestion)	46	50,0	50,0	23,9	32,6	30,4	13,0	0,0	0,0
2 (libérale)	133	61,7	38,3	11,3	33,8	39,8	9,8	1,5	3,8
5 (bureau)	94	76,6	23,4	27,7	46,8	22,3	3,2	0,0	0,0

Le tableau 7 se lit en ligne : chaque catégorie fait 100 %, et les pourcentages sont conditionnels (part des femmes parmi les personnes de la catégorie, part de chaque niveau d'études parmi les personnes de la catégorie ; Sec., Postsec., Bach., École et Doct. désignent les six groupes du tableau 6). Les catégories diffèrent sur deux points. Pour le sexe, la catégorie 5 (bureau) compte 76,6 % de femmes, contre 50,0 % dans la catégorie 1, alors que les femmes forment 49,6 % de l'échantillon. Pour les études, 54,9 % des membres de la catégorie 2 ont au moins un bachelor, contre 25,5 % dans la catégorie 5, où le groupe postsecondaire sans bachelor domine (46,8 %). Les niveaux rares reposent sur de très petits effectifs : la catégorie 2 compte 2 personnes d'école spécifique et 5 de doctorat.

Les effectifs bruts mèneraient ici à une erreur. La catégorie 2 compte plus de femmes (82) que la catégorie 5 (72) ; on pourrait en conclure qu'elle est plus féminisée. C'est l'inverse en proportion, parce que la catégorie 2 est plus grande (133 contre 94 personnes). Le choix du dénominateur compte aussi : sans l'argument `margin`, `prop.table()` divise par le total des 273 individus des trois catégories, et les femmes de la catégorie 5 en représentent alors 26,4 %. Ce pourcentage global décrit la composition du sous-ensemble ; il ne permet pas de comparer les catégories entre elles.

2.2.2 Distributions et indicateurs

Tableau 8: Indicateurs de position et de dispersion (effectif valide n)

Variable	n	Moyenne	Médiane	Écart-type	Q1	Q3	Min	Max
AGE (années)	599	41,85	42	14,12	29,0	53,5	16	80
SAL_HOR ($/h)	599	17,90	15	11,28	10,5	22,0	2	99
NB_PERS (personnes)	599	3,11	3	1,56	2,0	4,0	1	13
NB_ENF (enfants)	599	0,53	0	0,92	0,0	1,0	0	6

Pour les quatre variables, l'effectif valide est de 599 (tableau 8). Nous donnons à la fois moyenne et médiane, écart-type et quartiles : la comparaison des deux centres renseigne sur la symétrie, et les quartiles résistent aux valeurs extrêmes. L'âge est à peu près symétrique (moyenne 41,85 ans, médiane 42 ans). Pour NB_ENF, la médiane de 0 dit seulement qu'une majorité de foyers n'a pas d'enfant (68,9 %) ; la moyenne (0,53) complète cette information pour une variable discrète à peu de valeurs.

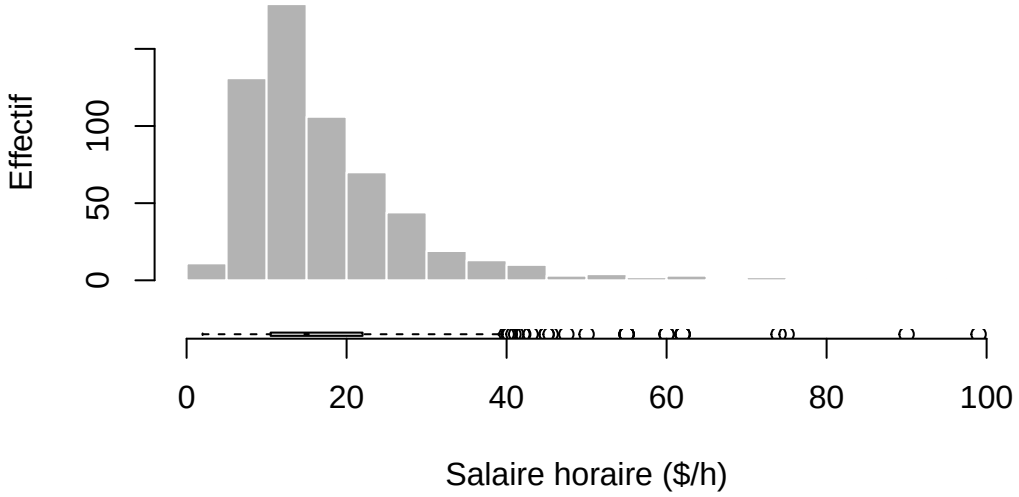


Figure 2: Distribution du salaire horaire ($/h) : histogramme en classes de 5 $/h et boîte à moustaches, n = 599

La distribution est nettement asymétrique à droite (figure 2). La classe la plus fréquente est 10–15 $/h (179 personnes), la moitié centrale des salaires tient entre 10,5 et 22 $/h, puis une longue queue s'étire jusqu'à 99 $/h. La boîte résume le centre et la dispersion, mais elle ne montre ni le mode ni la concentration des salaires sur des montants ronds. 57,4 % des salaires sont des nombres entiers de dollars, et 10 $/h apparaît à lui seul 33 fois, ce que seul un histogramme fin fait apparaître.

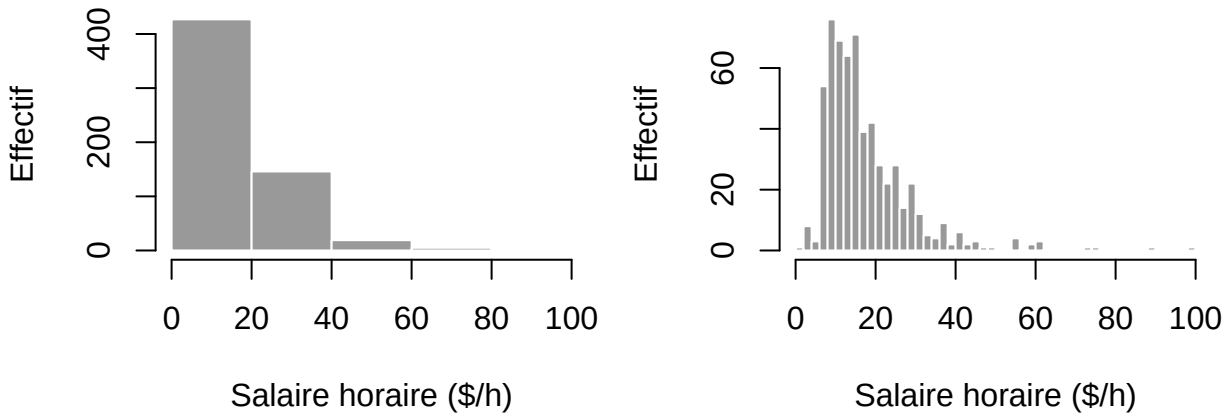


Figure 3: Deux découpages du salaire horaire ($/h) : classes de 20 $/h (à gauche) et de 2 $/h (à droite), n = 599

Le découpage change la lecture (figure 3). Avec 5 classes de 20 $/h, 71,3 % des individus tombent dans la première classe : on ne voit plus où se situe le mode, et la queue paraît se réduire à quelques barres. Avec 50 classes de 2 $/h, des pics isolés apparaissent sur les montants ronds et le dessin devient irrégulier ; certaines classes ne contiennent qu'un ou deux individus. Un découpage intermédiaire, comme celui de la figure 2, montre mieux la forme générale.

La moyenne du salaire horaire (17,90 $/h) dépasse la médiane (15 $/h) de 2,90 $/h, signe de l'asymétrie à droite : quelques salaires élevés tirent la moyenne vers le haut. La médiane décrit mieux le salaire « typique » de l'échantillon, la moyenne reste utile pour raisonner sur des totaux (une masse salariale, par exemple). Pour mesurer la sensibilité aux valeurs extrêmes, nous avons retiré les deux plus hauts salaires : la moyenne descend à 17,64 $/h, la médiane ne bouge pas (15 $/h).

L'écart interquartile vaut 11,5 $/h. La règle de 1,5 × IQR place les moustaches à -6,75 et 39,25 $/h. La borne basse est négative, donc aucun salaire ne peut se trouver en dessous ; 27 salaires dépassent la borne haute, de 40 à 99 $/h. Ces observations ne sont pas pour autant des erreurs : dans une distribution asymétrique, la règle signale des valeurs éloignées du centre, pas des valeurs fausses. Un salaire de 50 $/h (leur médiane) n'a rien d'invraisemblable pour un poste d'encadrement. Seuls les deux salaires supérieurs à 75 $/h méritent la vérification décrite plus haut.

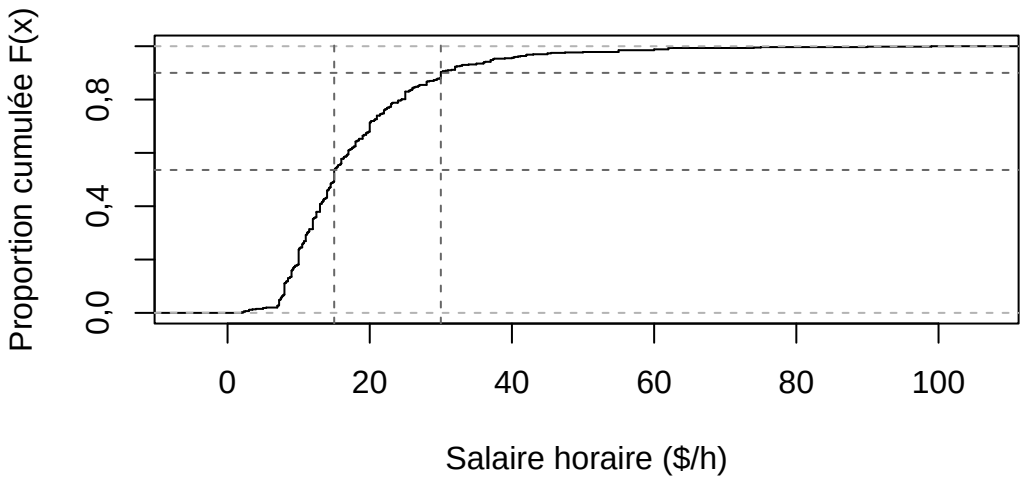


Figure 4: Fonction de répartition empirique du salaire horaire ($/h), n = 599

La fonction de répartition (figure 4) monte vite jusqu'à 30 $/h puis plafonne près de 1, ce qui traduit la même queue à droite. On y lit que $F(15) = 0{,}536$: 53,6 % des individus gagnent au plus 15 $/h. Dans l'autre sens, le quantile d'ordre 0,9 vaut 30 $/h : 90 % des salaires sont inférieurs ou égaux à ce montant. Les marches verticales sur les montants ronds rappellent l'accumulation déjà vue.

La variance descriptive divise la somme des carrés des écarts à la moyenne par n ; elle décrit la dispersion des valeurs observées. La variance corrigée divise par $n - 1$; elle sert à estimer la variance d'une population dont l'échantillon serait tiré, sans biais. La fonction `var()` de R utilise $n - 1$, dès qu'il y a au moins deux observations valides. Ici, `var(d$SAL_HOR)` donne 127,22 et la version descriptive 127,01 ($/h)². Le rapport entre les deux vaut $(n - 1)/n$, soit un écart de 0,17 % avec n = 599 : la distinction compte surtout pour de petits groupes.

2.2.3 Comparer et interpréter

Tableau 9: Salaire horaire ($/h) dans les catégories 1, 2 et 5 (n = 273)

Catégorie	n	Moyenne	Médiane	Écart-type	Q1	Q3
1 (gestion)	46	25,22	20	16,41	14,25	30
2 (libérale)	133	23,93	20	13,73	15,00	30
5 (bureau)	94	15,16	14	4,40	12,00	18

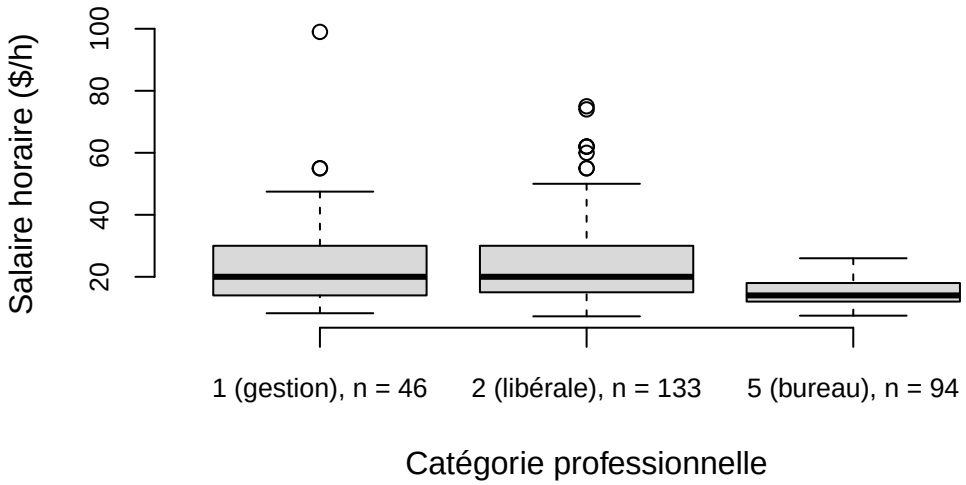


Figure 5: Salaire horaire ($/h) selon la catégorie professionnelle (1, 2 et 5), n = 273

Les catégories 1 et 2 ont la même médiane, 20 $/h, contre 14 $/h dans la catégorie 5 (tableau 9 et figure 5). La dispersion diffère plus encore que le centre : l'écart-type va de 4,4 $/h dans la catégorie 5 à 16,4 $/h dans la catégorie 1, et l'intervalle interquartile passe de 6,00 à 15,75 $/h. Les salaires de bureau sont donc à la fois plus bas et plus homogènes. La catégorie 1 repose sur 46 personnes seulement, et sa moyenne (25,22 $/h) dépend beaucoup de quelques hauts salaires.

Tableau 10: Salaire horaire ($/h) selon le sexe, ensemble puis catégories 1, 2 et 5

Champ	n F	Moyenne F	Médiane F	n M	Moyenne M	Médiane M
Ensemble (n = 599)	297	16,60	14,00	302	19,17	15,70
Catégorie 1 (gestion)	23	23,69	18,00	23	26,75	20,00
Catégorie 2 (libérale)	82	21,59	19,40	51	27,70	22,00
Catégorie 5 (bureau)	72	15,28	14,12	22	14,76	13,25

Sur l'ensemble de l'échantillon, la médiane des hommes dépasse celle des femmes de 1,7 $/h et la moyenne de 2,57 $/h (tableau 10). À l'intérieur des catégories, la conclusion n'est pas la même partout. L'écart en faveur des hommes s'observe dans les catégories 1 et 2, où il atteint 6,11 $/h en moyenne pour la catégorie 2. Dans la catégorie 5, il s'inverse : la médiane des femmes (14,12 $/h) dépasse celle des hommes (13,25 $/h). L'écart global peut aussi refléter la composition des catégories : les femmes sont surreprésentées dans la catégorie 5, la moins payée des trois. Les effectifs par cellule sont faibles (22 hommes dans la catégorie 5), ce qui interdit de généraliser.

Tableau 11: Salaire horaire ($/h) selon le niveau d'études regroupé (n = 599)

Groupe	n	Moyenne	Médiane
Secondaire ou moins	232	14,70	12,50
Postsec. sans bachelor	215	16,58	14,50
Bachelor	114	23,27	18,25
Master	29	26,89	19,80
École spécifique	4	18,53	18,56
Doctorat	5	48,20	37,00

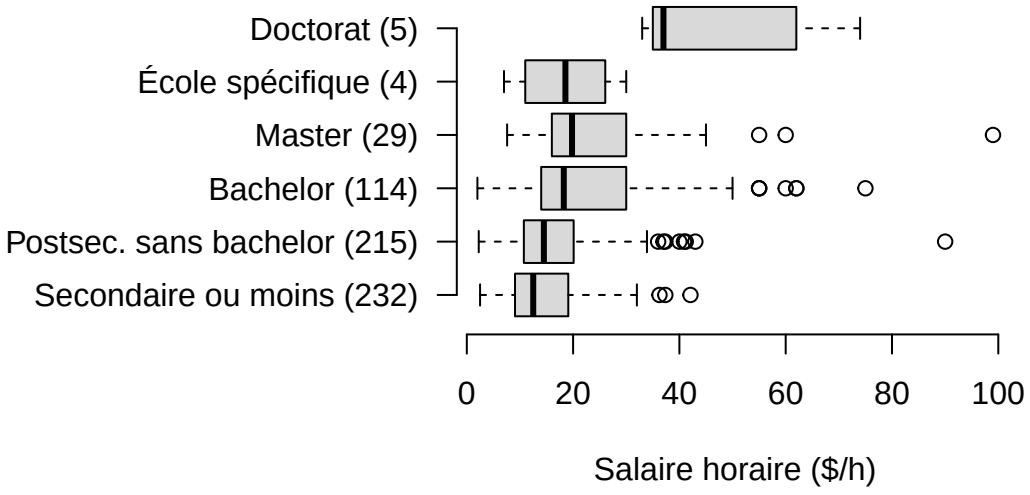


Figure 6: Salaire horaire ($/h) selon le niveau d'études regroupé, n = 599

La médiane du salaire augmente avec le niveau d'études, de 12,5 $/h pour le secondaire ou moins à 18,25 $/h pour le bachelor et 19,8 $/h pour le master (tableau 11, figure 6). Le doctorat affiche 37 $/h, mais sur 5 personnes. Le rapport de corrélation vaut $\eta^2 = 0{,}171$: c'est la part de la variance totale du salaire qui est inter-groupes (il varie de 0, groupes de même moyenne, à 1, salaire constant dans chaque groupe), soit 17,1 %

dans l'échantillon. C'est un indicateur purement descriptif. L'association est nette, mais elle ne prouve pas que le diplôme produit ces écarts : les plus diplômés peuvent aussi différer par leur métier, leur âge ou leur région, et rien ne permet ici de séparer ces facteurs.

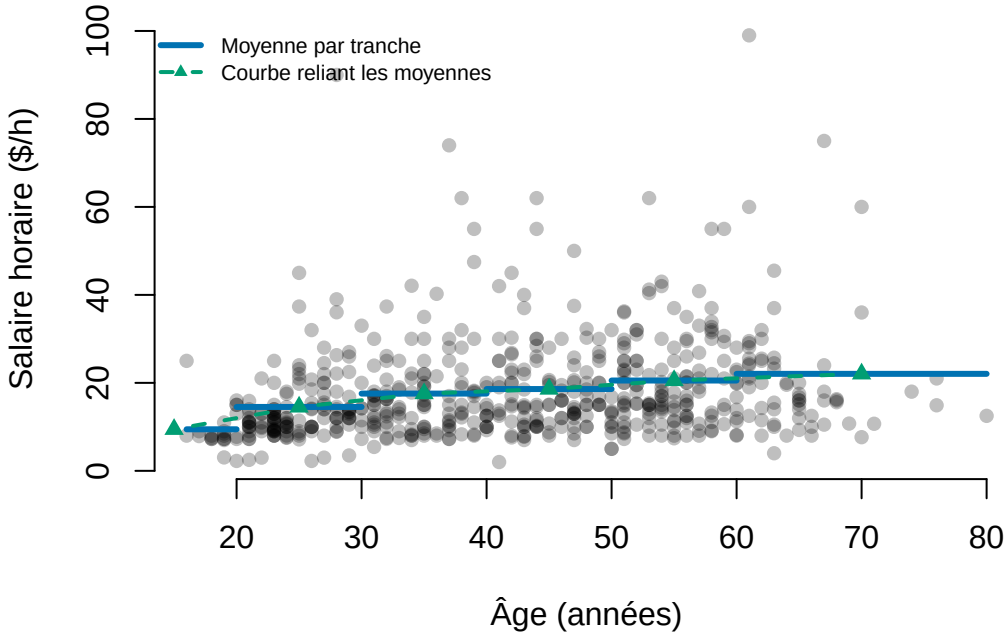


Figure 7: Salaire horaire ($/h) selon l'âge (années) : régressogramme (moyenne par tranche d'âge, bleu) et courbe reliant les moyennes aux centres des tranches (vert), n = 599

Le nuage (figure 7) est très dispersé. Pour dégager une tendance, nous traçons un régressogramme comme au cours : `cut()` découpe l'âge en tranches de 10 ans et `tapply()` calcule le salaire moyen de chaque tranche. Les âges vont de 16 à 80 ans : la première tranche,]10 ; 20], ne contient donc que des 16-20 ans (23 personnes), et nous regroupons 60 à 80 ans en une seule tranche (62 personnes), car il n'y a que 5 personnes de plus de 70 ans. Les autres tranches comptent de 121 à 137 personnes. Les moyennes sont placées aux centres des tranches (15, 25, . . . , 70 ans) ; pour les tranches extrêmes, nous gardons les milieux de]10 ; 20] et]60 ; 80], bien que les âges observés y soient 16-20 et 61-80 ans. Le salaire moyen monte vite, de 9,4 $/h chez les 16-20 ans à 17,6 $/h entre 30 et 40 ans, puis plus lentement, de 1,0 à 1,9 $/h par tranche : 18,6, 20,5 et 22,1 $/h dans les tranches suivantes. Le coefficient de corrélation linéaire est faible, r = 0,250, en partie parce que la relation n'est pas une droite. Les données sont de plus transversales : elles comparent des personnes de générations différentes en 2012, pas l'évolution du salaire d'une même personne. La première tranche ne repose que sur 23 personnes, la dernière regroupe vingt ans d'âge, et une moyenne reste sensible aux salaires très élevés : dans la tranche 60-80 ans, la médiane (17,75 $/h) est même un peu plus basse que celle des 50-60 ans (18 $/h).

Tableau 12: Part de syndiqués selon la catégorie (% en ligne), n = 599

	1	2	3	4	5	6	7	8	9	10
n	46	133	125	48	94	10	36	32	39	36
% syndiqués	10,9	24,8	16,0	6,2	10,6	0,0	33,3	25,0	17,9	13,9

La part de syndiqués varie de 0,0 % (catégorie 6, n = 10) à 33,3 % (catégorie 7, n = 36) pour une moyenne de 17,2 % (tableau 12) ; ces extrêmes reposent sur de petits effectifs et se lisent avec prudence. Ici encore, les

effectifs bruts tromperaient : la catégorie 2 compte le plus de syndiqués (33), mais pas le taux le plus élevé. Sur l'ensemble, la médiane des syndiqués (20 $/h, n = 103) dépasse celle des non-syndiqués (14 $/h, n = 496). Dans la catégorie 2, la seule où les syndiqués sont assez nombreux (n = 33, contre 100 non-syndiqués), l'ordre s'inverse : 17 $/h contre 20 $/h. Avec 5 syndiqués dans la catégorie 1 et 10 dans la catégorie 5, les données ne permettent pas de comparaison sérieuse.

En résumé, le salaire horaire est très asymétrique : la moyenne (17,90 $/h) dépasse la médiane (15 $/h) et 27 valeurs dépassent la moustache haute. Il est associé au niveau d'études, avec une médiane qui passe de 12,5 à 18,25 $/h entre le secondaire et le bachelor. L'écart entre hommes et femmes observé sur l'ensemble (1,7 $/h de médiane) ne se retrouve pas dans toutes les catégories et s'inverse dans la catégorie 5. Ces résultats ont deux limites. L'échantillon de 599 personnes n'est pas décrit comme représentatif, et certains sous-groupes sont minuscules (4 personnes pour l'école spécifique, 22 hommes dans la catégorie 5). Des variables importantes manquent, comme la durée du travail ou l'ancienneté, et les données datent de 2012.

2.3 Discussion critique de la Partie 1

Une différence de salaire entre deux groupes ne prouve ni une discrimination ni un lien de cause à effet. Les groupes comparés diffèrent sur d'autres points que celui qui les définit, et ces différences de composition suffisent à créer ou à masquer un écart : la comparaison par sexe en donne un exemple, puisque l'écart global change de sens dans la catégorie 5. Établir une discrimination demanderait de comparer des personnes semblables sur tout le reste, ce qu'une enquête descriptive de ce type ne permet pas. Des variables absentes du fichier pourraient modifier les comparaisons : le temps de travail (temps partiel ou temps plein, heures supplémentaires), l'ancienneté dans l'emploi et le secteur (public ou privé).

Tableau 13: Répartition des classes de REV_FOYER (n = 599)

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
n	9	5	5	9	7	19	26	38	30	35	61	70	71	89	77	48
%	1,5	0,8	0,8	1,5	1,2	3,2	4,3	6,3	5,0	5,8	10,2	11,7	11,9	14,9	12,9	8,0

Les classes de revenu du foyer décrivent une répartition ordonnée (tableau 13) : la classe médiane est la classe 12, et les classes 1 à 5 réunissent 5,8 % des foyers. Elles permettent aussi de comparer des groupes par leurs fréquences de classes. En revanche, elles empêchent de calculer exactement une moyenne, une variance ou un écart entre deux foyers : on ne connaît que l'intervalle, les classes n'ont pas toutes la même largeur et un code de classe n'est pas un montant. Il s'agit en outre d'un revenu de foyer, qu'on ne peut pas rapprocher directement du salaire horaire individuel.

Le dictionnaire du sujet présente une discontinuité entre les classes 5 et 6 : la classe 5 va de 12 500 à 14 500 $ et la classe 6 commence à 15 000 $ pour finir à 20 000 $. Un revenu compris entre 14 500 et 15 000 $ n'aurait donc pas de classe. Nous avons vérifié les données : les 16 classes sont toutes présentes, la classe 5 avec 7 foyers et la classe 6 avec 19. Aucune classe ne manque : l'incohérence vient des bornes du dictionnaire, peut-être d'une erreur de saisie que seul le dictionnaire complet de la CPS permettrait de trancher. Nous n'avons rien corrigé, puisque l'analyse n'utilise que les codes.

Nous n'avons pas traité l'option de comparaison avec un indicateur récent du BLS ou du Census Bureau : elle supposerait de vérifier le champ, les définitions et la période, et nous avons préféré consacrer la place à l'analyse des données de 2012.

3 Partie 2 : Régression sur Boston (1970)

3.1 Données et méthodes

Le jeu `Boston` du package `MASS` (`library(MASS)` puis `data("Boston")`) décrit 506 secteurs de la région de Boston d'après le recensement américain de 1970 : ce sont des données historiques, qui ne décrivent pas la

situation actuelle. Nous étudions X = `lstat` (pourcentage de la population de statut socio-économique faible, en %) et Y = `medv` (valeur médiane des logements, en milliers de dollars de 1970, notés k$, non actualisés). Les analyses sont descriptives et ne permettent aucune conclusion causale.

Fonctions R utilisées : `plot()`, `abline()` (nuage et droite), `lm()`, `summary()`, `coef()` (moindres carrés), `cor()` et `cor.test()` (corrélation), `fitted()`, `residuals()`, `sd()`, `sigma()`, `hist()`, `boxplot()` (ajustement et résidus), `predict()` (prévision), `cut()`, `tapply()`, `segments()`, `lines()`, `legend()` (régressogramme), `poly()` (polynômes de degré 2 à 4), `AIC()` (comparaison de modèles). Tous les chiffres de cette partie sont calculés dans ce document ; le script `tp_partie2.R` refait les mêmes calculs, tableaux et figures.

3.2 Résultats

3.2.1 Forme de la relation et droite de régression

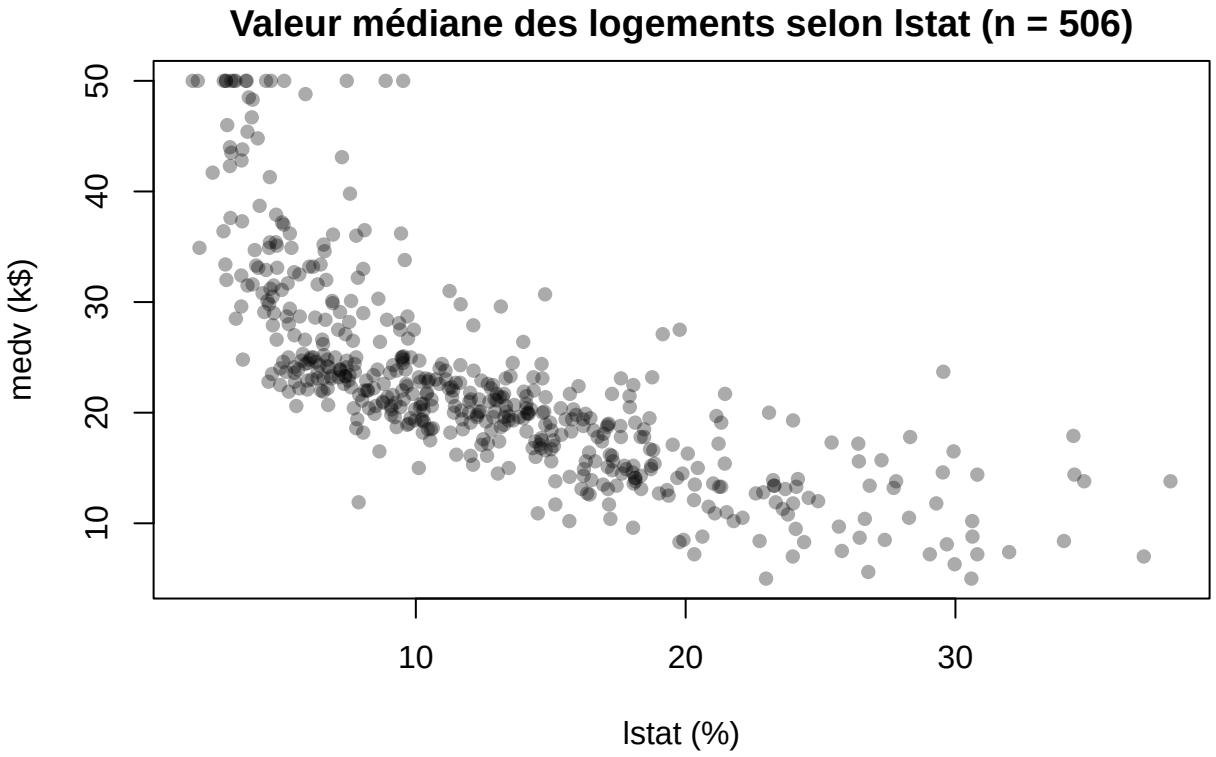


Figure 8: Valeur médiane des logements medv (k$) selon lstat (%), n = 506 secteurs

Le nuage (figure 8) décrit 506 secteurs de Boston, avec lstat de 1,73 à 37,97 % et medv de 5 à 50 k$. La relation est décroissante : plus la part de lstat est élevée, plus la valeur médiane des logements est basse. Elle est intense (corrélation linéaire r = -0,738) mais pas parfaitement linéaire : le nuage est convexe, medv chute vite quand lstat passe de quelques % à 10 %, puis décroît plus lentement. La dispersion verticale est aussi plus grande pour les faibles valeurs de lstat. Enfin, 16 secteurs ont medv = 50 k$ exactement : la variable semble plafonnée à cette valeur, ce qui limite l'interprétation en haut du nuage.

Tableau 14: Droite des moindres carrés de medv sur lstat : formules du cours et lm() (n = 506)

Coefficient	Formules	lm()	Erreur-type
Ordonnée à l'origine b0 (k$)	34,5538	34,5538	0,5626
Pente b1 (k$ par point de lstat)	-0,9500	-0,9500	0,0387

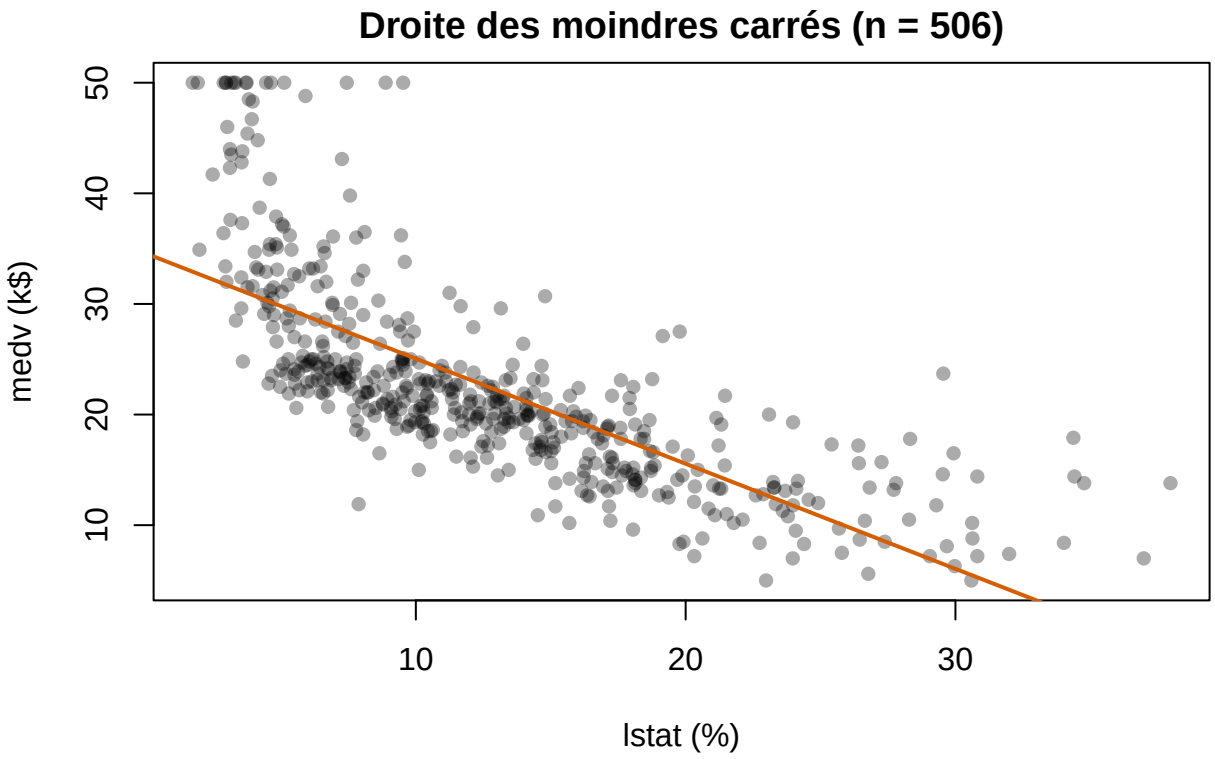


Figure 9: Nuage de medv (k$) selon lstat (%) et droite des moindres carrés, n = 506

Les deux calculs donnent la même droite (tableau 14) : $\hat{y} = 34{,}55 - 0{,}950\ x$, avec x = lstat (%) et $\hat{y}$ en k$. Les formules du cours, $b_1 = \mathrm{Cov}(x, y)/\mathrm{Var}(x)$ et $b_0 = \bar{y} - b_1\bar{x}$, coïncident avec `lm()` à la précision de la machine (`all.equal()`) ; le rapport Cov/Var est le même que l'on divise par n (cours) ou par $n - 1$ (`cov()`, `var()`). La pente vaut -0,950 : entre deux secteurs dont lstat diffère d'un point, la droite associe une valeur médiane des logements plus basse d'environ 950 $ de 1970 (0,95 k$). C'est une différence moyenne entre secteurs, pas l'effet d'une hausse de lstat dans un même secteur. L'ordonnée à l'origine, 34,55 k$, est la valeur prédite pour lstat = 0 ; aucun secteur n'a cette valeur (minimum 1,73 %), c'est donc une extrapolation légère qui sert surtout à placer la droite. La figure 9 montre que la droite passe au-dessus des points pour les lstat moyens et en dessous aux deux extrémités : elle ne suit pas la courbure vue sur le nuage.

3.2.2 Corrélation, test et valeurs ajustées

Le coefficient de corrélation linéaire vaut r = -0,738. Il mesure le sens et l'intensité de la liaison *linéaire* entre lstat et medv : il est compris entre -1 et 1, et son signe négatif confirme le sens décroissant. Le coefficient de détermination du modèle linéaire vaut $R^2 = 0{,}544$, soit exactement r^2 (0,544) pour une régression simple, et aussi le rapport $\mathrm{Var}(\hat{y})/\mathrm{Var}(y)$ du cours (0,544). Il mesure la part de la variance de medv reproduite par la droite : ici 54,4 %, les 45,6 % restants n'étant pas expliqués par un modèle linéaire en lstat.

Le test de corrélation de Pearson (`cor.test()`) porte sur $H_0 : \rho = 0$ (pas de liaison linéaire dans la population dont les secteurs seraient tirés) contre $H_1 : \rho \neq 0$, au seuil de 5 %. La statistique vaut t = -24,53 pour 504 degrés de liberté, et la p-valeur est inférieure à $2{,}2 \times 10^{-16}$; l'intervalle de confiance à 95 % de ρ est [-0,775 ; -0,695]. La p-valeur est très inférieure à 5 % : nous rejetons H_0 et concluons à une corrélation linéaire négative significative entre lstat et medv. Ce test suppose des couples indépendants et, pour sa forme exacte, une loi approximativement normale ; or des secteurs voisins se ressemblent, ce qui affaiblit ces hypothèses. Surtout, une corrélation, même significative, ne dit pas que lstat fait baisser medv : elle décrit seulement une association.

Tableau 15: Six premiers secteurs : valeurs observées, valeurs ajustées et résidus (n = 506)

Secteur	lstat (%)	medv observé (k$)	medv ajusté (k$)	Résidu (k$)
1	4,98	24,0	29,82	-5,82
2	9,14	21,6	25,87	-4,27
3	4,03	34,7	30,73	3,97
4	2,94	33,4	31,76	1,64
5	5,33	36,2	29,49	6,71
6	5,21	28,7	29,60	-0,90

Les valeurs ajustées `fitted(m)` sont les ordonnées de la droite aux lstat observés, $\hat{y}_i = b_0 + b_1 x_i$: ce que le modèle prévoit pour chaque secteur (tableau 15). Elles tiennent sur la droite, donc varient beaucoup moins que les valeurs observées : leur moyenne est celle de medv (22,53 k$) mais leur écart-type n'est que 6,78 k$, contre 9,20 k$ pour medv. La différence entre valeur observée et valeur ajustée est le résidu.

3.2.3 Résidus



Figure 10: Résidus du modèle linéaire (k$) : histogramme, boîte à moustaches et résidus selon lstat (lignes à ±2 écarts-types empiriques)

L'écart-type empirique des résidus, `sd(residuals(m))`, vaut 6,210 k$; `sigma(m)` vaut 6,216 k$. Les résidus ayant une moyenne nulle, `sd()` divise la somme des carrés des résidus par $n-1$, alors que `sigma()` la divise par $n-2$, soit $\sqrt{\sum e_i^2/(n-2)}$ avec $n-2 = 504$: deux paramètres (b_0 et b_1) ont été estimés. C'est `sigma(m)` qui estime l'écart-type des erreurs du modèle ; les deux valeurs diffèrent peu ici, car n est grand. La figure 10 montre trois défauts de l'ajustement linéaire. Les résidus sont asymétriques : ils vont de -15,2 à 24,5 k$, avec une queue à droite. Le nuage des résidus selon lstat n'est pas aplati autour de 0 : il dessine une courbe en U, avec des résidus plutôt positifs pour les faibles lstat et pour lstat > 25, négatifs au milieu, ce qui traduit la non-linéarité déjà vue. Enfin 31 secteurs (6,1 %) sortent de la bande ±2 écarts-types, presque tous par le haut (30), alors qu'on en attendrait environ 5 %, répartis des deux côtés, si les erreurs suivaient une loi normale.

3.2.4 Prévision

Nous choisissons lstat = 12 %, valeur située au cœur des observations (1,73 à 37,97 %). `predict()` donne medv prévu = 23,15 k$, soit 23 153 $ de 1970 : c'est la valeur médiane des logements attendue, en moyenne, pour un secteur dont lstat vaut 12 %. Cette prévision est très incertaine : les résidus ont un écart-type d'environ 6,2 k$, et la plupart des secteurs observés restent à moins de 2 `sigma(m)` de la droite, soit ± 12,4

k$. Un secteur réel de lstat = 12 % peut donc s'écarter nettement de la prévision, plutôt vers le haut vu l'asymétrie des résidus. La prévision n'est pertinente que dans le domaine observé de lstat.

3.2.5 Régressogramme

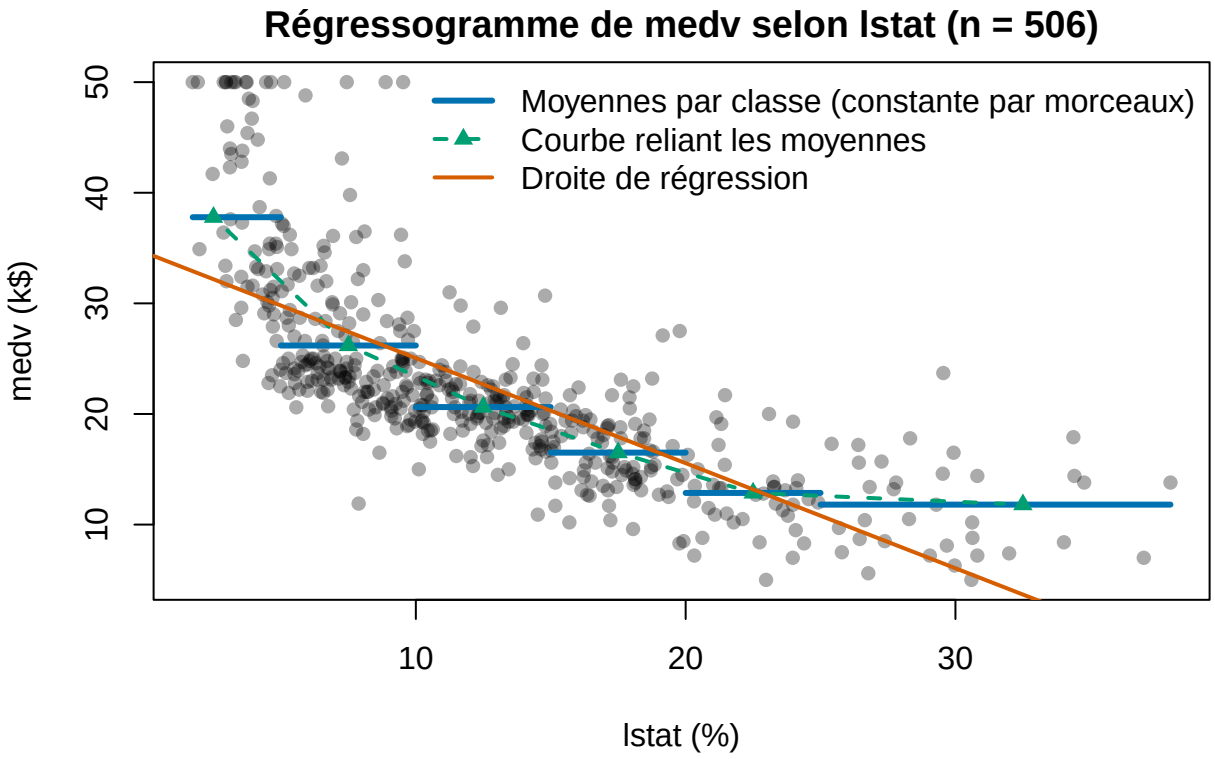


Figure 11: Régressogramme de medv (k$) selon lstat (%) : moyennes par classe (fonction constante par morceaux, bleu), courbe reliant les moyennes (vert) et droite de régression (rouge)

Tableau 16: Régressogramme : effectifs et moyennes de medv par classe de lstat (n = 506)

Classe	n	Abscisse retenue	Moyenne de medv (k$)	Résidu moyen de la droite (k$)
lstat ≤ 5	62	2,50	37,79	6,89
$5 <$ lstat ≤ 10	157	7,50	26,19	-1,24
$10 <$ lstat ≤ 15	125	12,50	20,63	-2,06
$15 <$ lstat ≤ 20	88	17,50	16,51	-1,62
$20 <$ lstat ≤ 25	40	22,50	12,86	-0,40
lstat > 25	34	32,50	11,81	5,42

Le découpage `cut(x, breaks = c(0, 5, 10, 15, 20, 25, 40))` donne exactement les six classes du sujet, puisque lstat va de 1,73 à 37,97 % (tableau 16), avec des effectifs très inégaux : de 34 à 157 secteurs. Pour la courbe reliant les moyennes, les abscisses sont les milieux des classes : 7,5, 12,5, 17,5 et 22,5 pour les classes bornées. Les deux classes extrêmes ne sont pas bornées dans le sujet. Pour la première, lstat est un pourcentage, donc jamais négatif : 0 est sa borne naturelle et nous prenons 2,5, milieu de [0 ; 5]. Pour la dernière, il n'y a pas de borne naturelle ; nous prenons 40, valeur ronde qui couvre le maximum observé (37,97 %), et donc 32,5, milieu de [25 ; 40]. La moyenne de medv descend de 37,8 k$ dans la première classe à 11,8 k$ dans la dernière : la baisse est rapide au début puis ralentit. Par rapport à la droite (figure 11), la

fonction constante par morceaux est au-dessus pour la première et la dernière classe (résidus moyens de 6,9 et 5,4 k$) et au-dessous aux classes intermédiaires (jusqu'à -2,1 k$). Elle suit mieux la courbure, mais ses marches dépendent du découpage choisi et chaque palier ne repose que sur les données de sa classe.

3.2.6 Polynômes et AIC

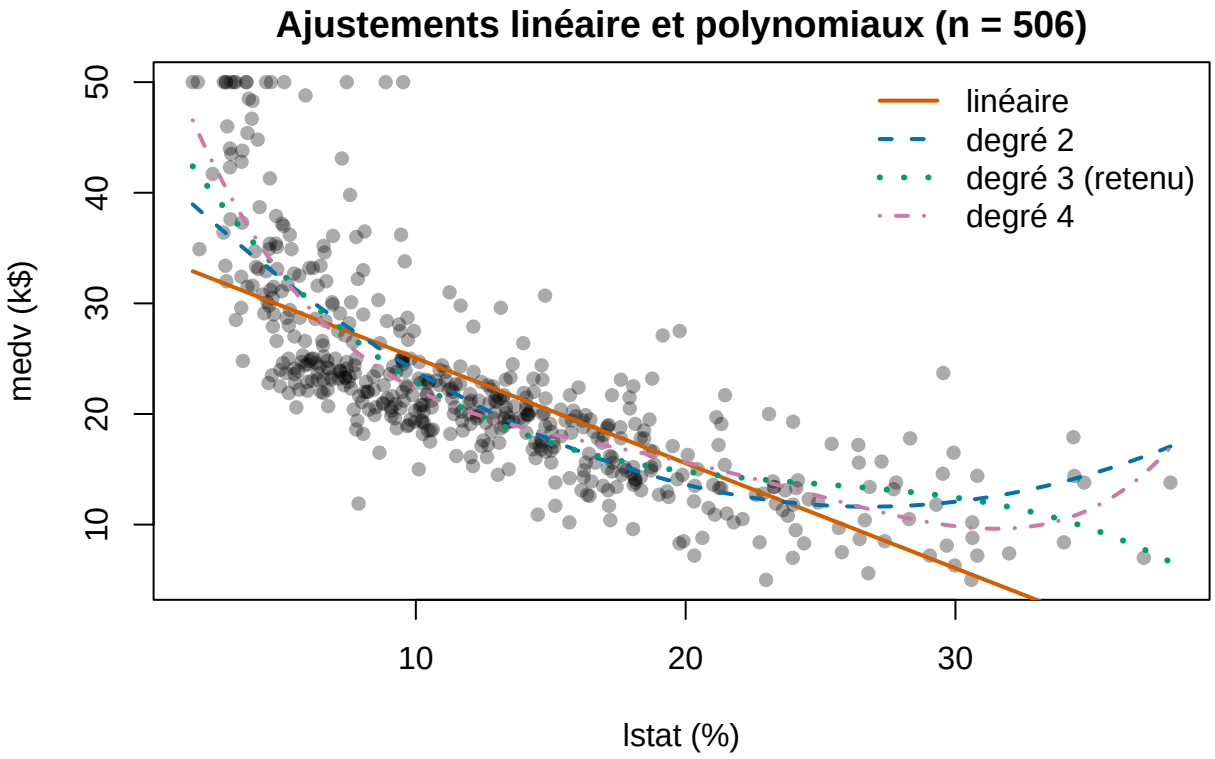


Figure 12: Ajustements linéaire et polynomiaux (degrés 2 à 4) de medv (k$) sur lstat (%)

Tableau 17: Modèles linéaire et polynomiaux : R^2 et AIC (n = 506)

Modèle	Paramètres	R^2	AIC
Linéaire	2	0,544	3 289,0
Degré 2	3	0,641	3 170,5
Degré 3	4	0,658	3 147,8
Degré 4	5	0,673	3 126,9

Le R^2 augmente à chaque degré : 0,544, 0,641, 0,658 puis 0,673 (tableau 17). Le gain est très net du linéaire au degré 2 (+0,097) puis modeste (+0,017 et +0,015). La courbe du degré 2 capte la convexité du nuage (figure 12) ; les degrés 3 et 4 en restent très proches au centre du nuage et diffèrent surtout aux extrémités. Un R^2 plus élevé sur les données d'ajustement ne garantit pas une meilleure prévision : le R^2 ne peut qu'augmenter quand on ajoute un terme, même sans valeur explicative réelle, et un polynôme de degré élevé finit par épouser le bruit de l'échantillon, d'où de mauvaises prévisions sur de nouveaux secteurs (surajustement). Le R^2 ne mesure que l'ajustement aux données ayant servi à estimer le modèle.

L'AIC, qui pénalise le nombre de paramètres, baisse à chaque degré : 3 289,0, 3 170,5, 3 147,8 puis 3 126,9 ; il est minimal au degré 4. Comme le demande le sujet, ce critère ne suffit pas à lui seul. Le gain d'AIC est énorme du linéaire au degré 2 (118 points), puis plus faible (22,7 points du degré 2 au degré 3, 20,9 du

degré 3 au degré 4) pour des courbes très proches sur la plage des données, alors que chaque degré ajoute un paramètre. Les graphiques comptent aussi : la courbe du degré 2 remonte à partir de lstat = 26,8 % et celle du degré 4 à partir de 31,5 % (7 secteurs au-delà), alors que les données ne montrent pas de remontée de medv pour les lstat élevés ; seul le degré 3 reste décroissant sur toute la plage observée. Nous retenons donc le **degré 3** : son R^2 est proche de celui du degré 4 (0,658 contre 0,673), il a un paramètre de moins et il reste décroissant, ce qui correspond à ce que montre le nuage. Ce choix reste discutable : l'AIC est plus bas de 20,9 points au degré 4, un écart du même ordre que celui du degré 2 au degré 3 ; c'est l'examen des graphiques et la complexité qui nous font préférer le degré 3, comme le recommande le cours (choix du degré d'après le graphe, les résidus et le degré le plus faible possible).

3.3 Discussion critique de la Partie 2

Les données datent de 1970 et portent sur des secteurs, non sur des individus : une corrélation entre secteurs ne se transpose pas à un secteur donné ni aux personnes qui y vivent (biais écologique). Le plafond de medv à 50 k$ (16 secteurs) tronque la variable en haut du nuage et contribue aux résidus positifs. La variable lstat, définie par le jeu de données comme un pourcentage de population de faible statut socio-économique, est une mesure agrégée dont la définition exacte relève du jeu de données historique. Les modèles ne sont comparés que sur les données ayant servi à les ajuster, et les secteurs voisins ne sont sans doute pas indépendants, ce qui fragilise les tests. Enfin, une association forte ($R^2 = 0{,}54$ pour le modèle linéaire) n'établit pas de lien de cause à effet : d'autres caractéristiques des secteurs, absentes de cette étude, peuvent expliquer à la fois lstat et medv.

4 Conclusion

Dans la Partie 1, le salaire horaire des 599 individus du fichier de 2012 est asymétrique à droite : la moyenne (17,90 $/h) dépasse la médiane (15 $/h). Il est associé au niveau d'études, avec une médiane qui passe de 12,5 à 18,25 $/h entre le secondaire et le bachelor. L'écart observé entre hommes et femmes sur l'ensemble ne se retrouve pas dans toutes les catégories professionnelles. Les données sont anciennes, l'échantillon n'est pas présenté comme représentatif et certaines variables importantes (temps de travail, ancienneté) manquent.

Dans la Partie 2, la valeur médiane des logements est plus basse dans les secteurs où lstat est élevé : la droite des moindres carrés ($\hat{y} = 34{,}55 - 0{,}950\ x$, $R^2 = 0{,}54$) résume la tendance, et le test de Pearson rejette l'absence de corrélation au seuil de 5 %. La liaison est pourtant courbée : nous retenons un polynôme de degré 3. L'AIC est minimal au degré 4 (3 126,9 contre 3 147,8), mais le degré 3 a un paramètre de moins et reste décroissant sur toute la plage observée, contrairement aux degrés 2 et 4.

Dans les deux parties, les résultats décrivent des associations et non des causes ; ils portent sur des données historiques de 1970 et 2012 et ne se transposent pas à la situation actuelle.

5 Bibliographie

- Université Paris Cité, *TP à rendre : statistique descriptive et régression sous R* (sujet du TP, adaptation du TP de statistique descriptive sur l'enquête CPS, juillet 2012).
- U.S. Census Bureau et Bureau of Labor Statistics, *Current Population Survey* (source de l'enquête de juillet 2012 dont est tiré `Recensement.txt`).
- Harrison D. et Rubinfeld D. L. (1978), « Hedonic prices and the demand for clean air », *Journal of Environmental Economics and Management*, 5, 81-102 (origine du jeu de données `Boston`).
- Venables W. N. et Ripley B. D. (2002), *Modern Applied Statistics with S*, 4e éd., Springer (package `MASS`).
- R Core Team, *R: A Language and Environment for Statistical Computing*, R Foundation for Statistical Computing, Vienne ; documentation des fonctions `lm`, `cor.test`, `predict`, `AIC` et `hist`.
- Supports du cours de statistique descriptive (statistique univariée, bivariée, liaison entre variables, régression).